



Universidade Federal do Acre

Guilherme de Jesus Carvalho

**Ciência de Dados Aplicada Na Detecção de Anomalias em
Portais de Transparências: Um Estudo de Caso do Governo do
Estado do Acre**

Rio Branco
2026

Guilherme de Jesus Carvalho

**Ciência de Dados Aplicada Na Detecção de Anomalias em
Portais de Transparências: Um Estudo de Caso do Governo do
Estado do Acre**

Universidade Federal do Acre

Orientador: Prof. Dra. Laura Costa Sarkis
Coorientador: Prof. Dra. Lorena Caceres Tomaya

Rio Branco
2026

LISTA DE ILUSTRAÇÕES

LISTA DE QUADROS

1	Cronograma de execução da pesquisa.	25
*		

SUMÁRIO

1	APRESENTAÇÃO	5
2	PROBLEMA DA PESQUISA	7
3	OBJETIVOS DA PESQUISA	9
3.1	Objetivo Geral	9
3.2	Objetivos Específicos	9
4	JUSTIFICATIVA DA PESQUISA	11
4.1	Relevância Social e Prática	11
4.2	Relevância Científica e Acadêmica	11
4.3	Relevância Técnica e Tecnológica	12
4.4	Viabilidade da Pesquisa	12
5	FUNDAMENTAÇÃO TEÓRICA	14
5.1	Transparência Pública, Dados Abertos e Controle Social	14
5.2	O Processo KDD (<i>Knowledge Discovery in Databases</i>) e a Análise Populacional	15
5.3	Filtros Estatísticos de Distribuição: Lei de Benford e Z-Score	16
5.4	Aprendizado de Máquina Não Supervisionado na Detecção de Anomalias	17
5.4.1	<i>Isolation Forest</i> (ISO)	17
5.4.2	<i>Local Outlier Factor</i> (LOF)	18
5.5	Mineração de Texto em Históricos Contábeis (NLP e DBSCAN)	19
5.6	Trabalhos Relacionados	20
6	PROCEDIMENTOS METODOLÓGICOS	22
7	RESULTADOS	23
7.1	PIPELINE KDD E COBERTURA POPULACIONAL	23
7.2	FILTRO ESTATÍSTICO DE BENFORD E Z-SCORE	23
7.2.1	Diagnóstico de Falsos Positivos	23
7.3	REDES DE GRAFOS E OLIGOPÓLIOS ESTRUTURAIS	23
7.4	ALGORITMO DE SMURFING E O ESTUDO DE CASO 4HEALTH	23
7.5	DIAGNÓSTICO FORENSE	24
8	CRONOGRAMA	25
	Referências	26

1 APRESENTAÇÃO

A crescente digitalização da administração pública e a consolidação dos portais de transparência governamentais têm disponibilizado volumes massivos de microdados sobre a execução orçamentária e financeira do setor público no Brasil. Contudo, a simples publicação bruta desses dados em tabelas e relatórios nem sempre se traduz em conhecimento acessível para a sociedade ou em insights estratégicos para a Gestão Pública, dada a elevada complexidade e assimetria das transações financeiras (Cavalcanti, 2014; Pereira, 2025). Neste cenário, a Ciência de Dados e o processo de Descoberta de Conhecimento em Bases de Dados (*Knowledge Discovery in Databases* – KDD) emergem como campos interdisciplinares fundamentais para transformar grandes volumes de dados não estruturados em conhecimento útil e interpretável (Goldschmidt, 2005). Em vez de recorrer a técnicas tradicionais de amostragem restrita, a aplicação de algoritmos computacionais permite o processamento populacional integral (100% dos registros), garantindo uma análise holística da dinâmica dos gastos públicos (Pereira, 2025). Como a base de dados do Portal da Transparência é composta por dados abertos não rotulados (*unlabelled data*) — isto é, sem a indicação prévia do que constitui um lançamento regular ou uma anomalia —, a aplicação de modelos de aprendizado de máquina supervisionado (como SVM e algoritmos de classificação) torna-se inviável na prática. Por essa razão, este projeto de pesquisa adota rigorosamente a abordagem de **Aprendizado de Máquina Não Supervisionado** (*Unsupervised Machine Learning*) e estatística descritiva, permitindo a descoberta de padrões ocultos e agrupamentos sem a necessidade de um gabarito prévio (Nunes *et al.*, 2021). O presente projeto de Trabalho de Conclusão de Curso (TCC) propõe o desenvolvimento de um pipeline computacional aplicado sobre a base populacional de despesas do Portal da Transparência do Estado do Acre, englobando mais de 429 mil registros financeiros referentes ao período de 2020 a 2025. O objetivo central deste estudo não reside na acusação criminal ou auditoria investigativa de ilícitos, mas sim no uso da Ciência de Dados para mapear, visualizar e compreender os fenômenos socioadministrativos reais que moldam a gestão pública acreana. Para a fase de execução e implementação da proposta, a metodologia do trabalho integrará os seguintes pilares analíticos:

1. **Filtro Estatístico Paramétrico (Lei de Benford e Z-Score):** Utilizado como linha de base estatística para analisar a distribuição natural dos dígitos financeiros e identificar padronizações normativas, tais como a concentração de valores tabelados em diárias operacionais e auxílios institucionais (Cavalcanti, 2014; Nigrini, 2012);
2. **Algoritmos Não Supervisionados de Detecção de Anomalias:** Aplicação planejada dos algoritmos *Isolation Forest* (ISO) (Liu; Ting; Zhou, 2008) e *Local Outlier Factor* (LOF) (Breunig *et al.*, 2000) para o isolamento computacional de desvios e pontos discrepantes na distribuição dos gastos;

3. **Mineração de Texto e Agrupamento (NLP e DBSCAN):** Emprego de técnicas de Processamento de Linguagem Natural combinadas com algoritmos de agrupamento baseados em densidade para analisar os históricos contábeis e identificar contratos continuados em serviços essenciais;
4. **Representação Relacional Complementar:** Uso secundário de estruturas de redes para a representação visual da topologia de fornecedores e secretarias estaduais (Nunes *et al.*, 2021).

Dessa forma, esta pesquisa contribui para a literatura de Ciência de Dados Aplicada ao demonstrar como técnicas computacionais não supervisionadas podem servir como instrumentos de inteligência institucional, revelando dinâmicas organizacionais, gargalos normativos e padrões de alocação de recursos no Estado do Acre.

2 PROBLEMA DA PESQUISA

A garantia da transparência pública e o fortalecimento do controle social no Brasil foram impulsionados pela promulgação da Lei de Acesso à Informação (Lei nº 12.527/2011) e pela Lei de Responsabilidade Fiscal (Lei Complementar nº 101/2000). Esses marcos normativos obrigaram os entes federativos a disponibilizarem, em meios eletrônicos, informações detalhadas sobre a execução orçamentária em tempo real. No entanto, os portais de transparência governamentais abrigam bases dinâmicas com milhões de lançamentos contínuos acumulados ao longo dos anos. Essa escala massiva frequentemente resulta no fenômeno da "opacidade por excesso" (*information overload*), no qual a simples publicação bruta de dados não estruturados cria barreiras para a interpretação pública (Cavalcanti, 2014; Pereira, 2025). No âmbito do controle institucional, órgãos formais como a Controladoria-Geral da União (CGU) e os Tribunais de Contas Estaduais (TCE) dispõem de auditores especializados e sistemas proprietários de inteligência para fiscalização interna. Contudo, essas ferramentas restritas não estão acessíveis à sociedade civil, a jornalistas de dados e à comunidade acadêmica, que dependem exclusivamente dos microdados abertos publicados nos portais. Para este público, a análise manual de bases massivas mostra-se inviável, demandando metodologias abertas de Ciência de Dados para a automação da triagem e extração de conhecimento (Nunes *et al.*, 2021). No contexto da pesquisa "**Ciência de Dados Aplicada na Detecção de Anomalias em Portais de Transparência: Um Estudo de Caso do Governo do Estado do Acre**", a análise foca no recorte populacional de mais de 429 mil registros financeiros referentes ao período de 2020 a 2025. A partir desse ecossistema de dados abertos, emergem desafios centrais de Ciência de Dados e Aprendizado de Máquina (*Machine Learning*):

1. **Ausência de Rotulagem (*Unlabelled Data*):** Os dados abertos dos portais de transparência não possuem rotulação prévia (*ground truth*) que identifique empenhos normais ou anômalos. A inexistência de um gabarito inviabiliza o uso direto de modelos supervisionados (como SVM e Árvores de Decisão), exigindo o emprego de algoritmos de **Aprendizado Não Supervisionado** (*Isolation Forest – ISO, Local Outlier Factor – LOF e DBSCAN*) aliados a testes de distribuição estatística (Lei de Benford e Z-Score) (Nunes *et al.*, 2021; Goldschmidt, 2005);
2. **Complexidade Normativa e Falsos Positivos:** O uso isolado de testes estatísticos pode gerar falsos positivos ao identificar concentrações de pagamentos perfeitamente legítimos, mas tabelados por decretos (como diárias e auxílios operacionais). A superação desse gargalo exige a integração de técnicas de Processamento de Linguagem Natural (NLP) sobre os históricos contábeis para contextualizar o texto livre das despesas (Cavalcanti, 2014);

3. **Ineditismo e Lacuna de Pesquisa na Região Acreana:** A literatura nacional sobre Ciência de Dados e transparência pública concentra suas aplicações predominantemente na esfera federal ou em estados do Sul e Sudeste (Cavalcanti, 2014; Nunes *et al.*, 2021). O levantamento exploratório confirma a escassez de estudos computacionais dedicados à infraestrutura e aos microdados do Portal da Transparência do Estado do Acre, evidenciando uma lacuna científica regional que justifica a realização deste estudo de caso.

Diante dessa problemática, formula-se a seguinte **Pergunta de Pesquisa** que orienta este trabalho:

Em que medida a aplicação de um pipeline de Ciência de Dados baseado em Aprendizado Não Supervisionado (Isolation Forest, Local Outlier Factor e DBSCAN), testes estatísticos descritivos (Lei de Benford e Z-Score) e Processamento de Linguagem Natural permite identificar, filtrar e interpretar anomalias e padrões socioadministrativos nos microdados abertos do Portal da Transparência do Estado do Acre (2020–2025), sem a necessidade de dados previamente rotulados?

3 OBJETIVOS DA PESQUISA

Com o intuito de responder à pergunta de pesquisa formulada e viabilizar a análise computacional dos microdados abertos do setor público, este capítulo delimita o objetivo geral e os objetivos específicos que norteiam o desenvolvimento deste trabalho.

3.1 Objetivo Geral

Desenvolver e avaliar uma metodologia baseada em técnicas de Ciência de Dados e Aprendizado de Máquina para detectar padrões anômalos nas despesas públicas registradas no Portal da Transparência e relacionadas ao Estado do Acre, identificando transações ou grupos de transações que apresentem comportamento atípico em relação aos padrões históricos de execução da despesa.

3.2 Objetivos Específicos

Para o alcance do objetivo geral, estabelecem-se os seguintes objetivos específicos:

1. **Obtenção e Pré-processamento de Dados:** Obter, organizar e realizar o pré-processamento dos dados de despesas públicas relacionadas ao Estado do Acre disponíveis no Portal da Transparência, considerando as variáveis financeiras, temporais, institucionais e cadastrais disponíveis;
2. **Caracterização Estatística Exploratória:** Caracterizar estatisticamente o comportamento das despesas, avaliando sua distribuição, concentração, variabilidade e evolução temporal segundo órgão, unidade gestora, favorecido, natureza da despesa e demais categorias disponíveis;
3. **Engenharia de Atributos (*Feature Engineering*):** Construir atributos capazes de representar comportamentos potencialmente atípicos das despesas, considerando, além do valor da transação, características como frequência, recorrência, concentração por favorecido e variação temporal;
4. **Modelagem Não Supervisionada:** Aplicar técnicas de Aprendizado de Máquina Não Supervisionado para identificar observações ou padrões anômalos nas despesas analisadas;
5. **Comparação e Concordância Algorítmica:** Comparar o desempenho e a concordância entre diferentes métodos de detecção de anomalias, identificando despesas classificadas como atípicas por uma ou mais técnicas;

6. **Investigação Socioadministrativa dos Padrões:** Investigar a distribuição das anomalias identificadas segundo órgãos, favorecidos, categorias de despesa e períodos de execução, buscando reconhecer padrões recorrentes;
7. **Construção de Escore de Priorização:** Desenvolver um escore ou classificação de prioridade das observações detectadas, de forma a auxiliar na seleção das despesas que mereçam análise mais detalhada;
8. **Avaliação de Impacto e Aplicabilidade:** Avaliar a aplicabilidade das técnicas de Ciência de Dados como instrumento complementar de transparência e controle dos gastos públicos.

4 JUSTIFICATIVA DA PESQUISA

A relevância deste Trabalho de Conclusão de Curso fundamenta-se na interseção entre a Ciência de Dados, a Ciência da Informação e a Gestão Pública, desdobrando-se nas dimensões social, científica, técnica e prática.

4.1 Relevância Social e Prática

A consolidação do princípio constitucional da publicidade e os avanços promovidos pela Lei de Acesso à Informação (Lei nº 12.527/2011) garantiram o direito fundamental de acesso aos dados orçamentários do setor público brasileiro. Contudo, a simples publicação de relatórios contábeis extensos e dados brutos nos portais de transparência não assegura, por si só, a efetividade da transparência pública. Na prática, a sociedade civil, jornalistas de dados e a comunidade acadêmica enfrentam o fenômeno da "opacidade por excesso" (*information overload*), no qual o volume massivo e desestruturado de informações impede a compreensão direta sobre como os recursos públicos estão sendo alocados (Cavalcanti, 2014; Pereira, 2025).

Nesse contexto, a aplicação de técnicas de Ciência de Dados atua como um instrumento de democratização da informação e fortalecimento do controle social. Ao transformar microdados financeiros brutos em representações analíticas compreensíveis e padrões interpretáveis, a pesquisa contribui para reduzir a assimetria de informação entre a administração governamental e o cidadão. Além disso, no âmbito prático da gestão pública, o desenvolvimento de mecanismos abertos de triagem automatizada permite identificar gargalos normativos e padrões atípicos de execução orçamentária, fornecendo subsídios para o aprimoramento da eficiência administrativa e do planejamento de políticas públicas no Estado do Acre.

4.2 Relevância Científica e Acadêmica

Apesar da expansão de pesquisas dedicadas ao uso de técnicas computacionais e estatísticas na fiscalização de gastos públicos no Brasil, observa-se que a literatura científica nacional concentra suas aplicações predominantemente em dados federais — como o Cartão de Pagamento do Governo Federal (CPGF) e o SICONFI — ou em grandes metrópoles das regiões Sul e Sudeste (Cavalcanti, 2014; Nunes *et al.*, 2021). Em contrapartida, o ecossistema de dados abertos dos entes subnacionais da Região Norte, em especial do Estado do Acre, permanece subexplorado pela pesquisa em Ciência de Dados e Sistemas de Informação.

O ineditismo regional desta pesquisa reside justamente na aplicação e validação de um pipeline computacional não supervisionado sobre a base populacional de despesas do Poder Executivo do Estado do Acre. Do ponto de vista científico, o estudo preenche uma lacuna relevante

na literatura ao investigar como modelos de detecção de anomalias e testes estatísticos de distribuição comportam-se diante das especificidades orçamentárias, normativas e fornecedoras de uma unidade federativa da Amazônia Sul-Occidental. Assim, o trabalho amplia a validade externa das metodologias de Ciência de Dados aplicadas à transparência pública, fornecendo um arcabouço metodológico reprodutível e replicável para outros estados com dinâmicas administrativas semelhantes (Pereira, 2025).

4.3 Relevância Técnica e Tecnológica

Do ponto de vista tecnológico e computacional, a justificativa deste trabalho assenta-se na superação dos limites impostos pelas abordagens analógicas e amostrais tradicionais de fiscalização. A análise populacional integral — que abrange 100% dos mais de 429 mil registros do recorte temporal estipulado — garante que nenhum evento atípico seja omitido por viés de seleção ou corte arbitrário de dados, aumentando a confiabilidade da triagem (Pereira, 2025).

Ademais, a arquitetura metodológica proposta responde a um desafio técnico central na mineração de dados abertos governamentais: a ausência de rótulos prévios (*unlabelled data*). Ao integrar modelos de Aprendizado de Máquina Não Supervisionado (*Isolation Forest*, *Local Outlier Factor* e *DBSCAN*) a testes estatísticos de distribuição (Lei de Benford e Z-Score) e técnicas de Processamento de Linguagem Natural (NLP), a pesquisa estabelece um pipeline computacional capaz de identificar anomalias estruturais e isolar falsos positivos decorrentes de regras normativas da administração pública (Cavalcanti, 2014; Nunes *et al.*, 2021; Goldschmidt, 2005). Trata-se de uma solução tecnológica reprodutível e orientada à automação do processo de triagem contábil.

4.4 Viabilidade da Pesquisa

A viabilidade técnica, operacional e temporal deste projeto de pesquisa é plenamente assegurada pela conjugação de três fatores fundamentais: a disponibilidade de dados públicos abertos, o uso de ecossistemas computacionais de código aberto (*open-source*) e o avanço prévio do pipeline de dados.

Em primeiro lugar, a garantia de acesso aos microdados é respaldada pela legislação nacional de transparência (Lei nº 12.527/2011), uma vez que a totalidade das informações necessárias provém do Portal da Transparência do Estado do Acre, um ecossistema de dados abertos e de livre acesso que não impõe barreiras legais ou restrições de sigilo à extração de dados orçamentários.

Em segundo lugar, a exequibilidade computacional do trabalho apoia-se no uso da linguagem de programação Python e do seu ecossistema científico especializado (*pandas*, *numpy*, *scikit-learn*, *seaborn* e *networkx*). A opção por bibliotecas abertas e consolidadas elimina a dependência de licenças de software proprietário de alto custo e assegura a transparência e a reprodutibilidade integral do pipeline analítico (Pereira, 2025).

Por fim, a viabilidade cronológica é corroborada pela fase adiantada de preparação da base de dados. O processo de extração, limpeza e padronização do recorte populacional do Estado do Acre (2020–2025) — englobando mais de 429 mil registros financeiros — já se encontra concluído e validado em ambiente computacional. Esse amadurecimento técnico prévio mitiga riscos operacionais e assegura o cumprimento rigoroso do cronograma acadêmico estipulado para a execução do TCC.

5 FUNDAMENTAÇÃO TEÓRICA

Neste capítulo, apresentam-se os conceitos teóricos, modelos estatísticos, algoritmos computacionais e estudos correlatos que sustentam o desenvolvimento desta pesquisa.

5.1 Transparência Pública, Dados Abertos e Controle Social

A consolidação da transparência na administração pública brasileira é resultado de um processo histórico de aperfeiçoamento institucional e normativo, impulsionado pela promulgação da Lei de Responsabilidade Fiscal (Lei Complementar nº 101/2000) e pela Lei de Acesso à Informação (Lei nº 12.527/2011 – LAI). Esses marcos legalmente formalizaram a transição do modelo tradicional de sigilo administrativo para o paradigma da transparência ativa, no qual a publicidade passa a ser a regra geral e o sigilo, a exceção. Como decorrência, os entes federativos passaram a ser obrigados a disponibilizar, em portais de acesso público na internet, dados em tempo real sobre a execução orçamentária, financeira e operacional do setor público (Cavalcanti, 2014; Pereira, 2025).

Entretanto, a disponibilização bruta de dados nos portais de transparência governamentais expõe uma limitação crítica da transparência passiva e ativa não mediadas por ferramentas analíticas. Na literatura de Ciência da Informação e Gestão Pública, esse fenômeno é denominado "opacidade por excesso" (*information overload*). A publicação de tabelas com centenas de milhares de linhas, caracterizadas por descrições contábeis genéricas, ausência de metadados consolidados e falta de filtros inteligentes, cria uma barreira cognitiva para o cidadão comum, para jornalistas de dados e para a comunidade acadêmica (Cavalcanti, 2014; Nunes *et al.*, 2021). Embora o dado esteja formalmente acessível do ponto de vista jurídico, ele permanece ininteligível do ponto de vista prático e social.

A superação desse obstáculo é condição fundamental para o pleno exercício do controle social — mecanismo pelo qual a sociedade civil organizada participa da fiscalização e do acompanhamento da aplicação dos recursos públicos. Conforme destacado por Nunes *et al.* (2021), a efetividade da transparência governamental não reside na mera exibição técnica de dados de despesas, mas na transformação desses microdados em conhecimento estruturado, capaz de apontar autonomamente comportamentos atípicos e sinalizar padrões de alocação de recursos que exijam análise aprofundada (Nunes *et al.*, 2021).

Assim, o uso da Ciência de Dados e de sistemas computacionais abertos posiciona-se como uma ponte entre a disponibilidade legal do dado público e o seu aproveitamento prático pelo controle social, viabilizando a automação do processo de triagem sobre bases populacionais volumosas sem depender exclusivamente de auditorias analógicas ou de conhecimento especializado contábil (Nunes *et al.*, 2021; Pereira, 2025).

5.2 O Processo KDD (*Knowledge Discovery in Databases*) e a Análise Populacional

A extração de conhecimento a partir de grandes volumes de dados brutos exige a aplicação de metodologias estruturadas que orientem o tratamento da informação desde a sua coleta até a interpretação dos resultados. Na Ciência de Dados e na Mineração de Dados (*Data Mining*), o modelo conceitual amplamente aceito para essa finalidade é o processo de Descoberta de Conhecimento em Bases de Dados (*Knowledge Discovery in Databases* – KDD) (Goldschmidt, 2005; Pereira, 2025).

O ciclo KDD caracteriza-se por ser uma abordagem iterativa e sequencial, composta por cinco etapas fundamentais (Goldschmidt, 2005):

1. **Seleção:** Identificação e extração do conjunto de dados relevante (*dataset*) a partir das fontes operacionais brutas;
2. **Pré-processamento e Limpeza:** Higienização da base mediante o tratamento de valores ausentes, remoção de inconsistências, eliminação de duplicatas e correção de ruídos de formatação;
3. **Transformação:** Padronização dos tipos de dados, engenharia de atributos (*feature engineering*) e adequação das variáveis para os formatos exigidos pelos algoritmos analíticos;
4. **Mineração de Dados (*Data Mining*):** Aplicação de modelos estatísticos e algoritmos computacionais para o mapeamento e extração de padrões, agrupamentos e anomalias;
5. **Pós-processamento e Interpretação:** Validação, visualização e consolidação dos padrões descobertos em conhecimento útil e compreensível para o domínio de aplicação.

No contexto da gestão pública e do controle de gastos, a adoção do arcabouço KDD viabiliza uma mudança paradigmática fundamental: a transição das revisões analógicas baseadas em amostragem estatística restrita para a **Análise Populacional Integral (100% da base de dados)** (Pereira, 2025). As abordagens tradicionais de auditoria contábil frequentemente dependem de cortes amostrais arbitrários, o que cria pontos cegos e aumenta o risco de omissão de eventos atípicos pulverizados ou fracionados.

Por outro lado, o processamento da totalidade dos registros financeiros disponibilizados no Portal da Transparência elimina o viés de seleção amostral, assegurando que todas as transações passem pelo mesmo crivo analítico. Conforme demonstrado por Pereira (2025), a combinação da análise populacional com o pipeline KDD otimiza a alocação de esforços humanos de fiscalização, atuando como um filtro prévio automatizado que direciona a atenção dos analistas estritamente para as observações com elevados indicadores de atipicidade (Pereira, 2025).

5.3 Filtros Estatísticos de Distribuição: Lei de Benford e Z-Score

A análise da distribuição de frequências dos dígitos numéricos em bases de dados financeiras constitui uma técnica clássica da contabilidade forense e da Ciência de Dados para a identificação primária de anomalias estatísticas. O pilar fundamental dessa abordagem é a Lei de Newcomb-Benford (também conhecida como a Lei do Primeiro Dígito Significativo), descrita originalmente pelo astrônomo Simon Newcomb em 1881 e redescoberta pelo físico Frank Benford em 1938 (Nigrini, 2012; Pereira, 2025).

Diferentemente da intuição comum, que pressupõe uma distribuição uniforme na qual cada dígito de 1 a 9 teria 11,1% de probabilidade de ocupar a primeira posição em um número, a Lei de Benford demonstra que dados numéricos decorrentes de fenômenos naturais, sociais e econômicos não manipulados obedecem a uma distribuição logarítmica. Matematicamente, a probabilidade $P(d)$ de um número iniciar com o dígito $d \in \{1, 2, \dots, 9\}$ é dada pela Equação 5.1:

$$P(d) = \log_{10} \left(1 + \frac{1}{d} \right) \quad (5.1)$$

Conforme essa distribuição, o dígito 1 possui a maior probabilidade teórica de ocorrência (aproximadamente 30,1%), enquanto o dígito 9 apresenta a menor probabilidade (aproximadamente 4,6%). Quando dados financeiros sofrem manipulação humana deliberada ou ajustes artificiais — como o fracionamento de compras para burlar limites de licitação (*smurfing*) —, a distribuição natural dos dígitos tende a ser distorcida, gerando um desvio detectável frente à curva teórica (Nigrini, 2012; Cavalcanti, 2014).

Para avaliar a conformidade de uma base de dados pública frente à Lei de Benford, a literatura estabelece dois testes estatísticos complementares (Nigrini, 2012; Pereira, 2025):

1. **Teste Qui-Quadrado (χ^2):** Utilizado para testar a hipótese nula (H_0) de aderência global da base de dados, determinando se a distribuição observada dos dígitos desvia significativamente da distribuição teórica esperada em nível macro;
2. **Teste Z-Score:** Empregado para avaliar o desvio atômico e localizado de cada dígito individualmente, medindo quantos desvios-padrão a frequência observada dista da frequência teórica de Benford.

No entanto, a aplicação da Lei de Benford sobre microdados abertos da administração pública exige cautela analítica para evitar interpretações equivocadas. Como ressaltado por Cavalcanti (2014), picos de frequência observados em dígitos específicos (medidos por Z-Scores elevados) nem sempre sinalizam irregularidades ou fraudes intencionais. No setor público, desvios estatísticos severos frequentemente decorrem de regras de negócio rígidas e padronizações normativas — tais como concessões de diárias operacionais com valores fixados por decreto, reembolsos padronizados e tabelamento de auxílios. Portanto, o filtro estatístico de Benford deve

ser compreendido como um mecanismo descritivo de sinalização de atipicidade (*red flag*), cuja validação requer a integração com técnicas contextuais de mineração de texto e aprendizado de máquina (Cavalcanti, 2014; Nunes *et al.*, 2021).

5.4 Aprendizado de Máquina Não Supervisionado na Detecção de Anomalias

O Aprendizado de Máquina (*Machine Learning*) é a subárea da Inteligência Artificial dedicada ao desenvolvimento de algoritmos capazes de extrair conhecimento, identificar padrões e tomar decisões de forma automatizada a partir de dados históricos (Goldschmidt, 2005). No domínio da detecção de anomalias, as técnicas de aprendizado dividem-se fundamentalmente em duas abordagens: **supervisionadas** e **não supervisionadas** (Nunes *et al.*, 2021).

Nas abordagens supervisionadas (como *Support Vector Machines* – SVM, Árvores de Decisão e Regressão Logística), o modelo exige um conjunto de dados previamente rotulado (*labelled dataset*), no qual cada registro é formalmente classificado entre "regular" ou "anômalo" (*ground truth*). Contudo, como ressaltado por Nunes *et al.* (2021), a aplicação de modelos supervisionados sobre dados de finanças públicas é inviável na prática, uma vez que os microdados abertos dos portais de transparência não possuem rotulagem prévia de auditoria (Nunes *et al.*, 2021).

Diante da ausência de rótulos, a extração de atipicidades fundamenta-se no **Aprendizado de Máquina Não Supervisionado** (*Unsupervised Learning*). Essa abordagem assume que a imensa maioria dos registros da base representa transações normais e legítimas, enquanto as anomalias correspondem a observações raras que se distanciam estruturalmente do comportamento padrão (Goldschmidt, 2005; Nunes *et al.*, 2021). Para a execução deste projeto, destacam-se dois algoritmos não supervisionados consolidados na literatura:

5.4.1 *Isolation Forest* (ISO)

Proposto originalmente por Liu, Ting e Zhou (2008), o *Isolation Forest* (ISO) adota uma abordagem distinta dos algoritmos tradicionais baseados em distância ou densidade. Em vez de construir perfis de dados normais para posterior identificação de desvios, o ISO foca no **isolamento explícito das anomalias** (Liu; Ting; Zhou, 2008).

O algoritmo opera mediante a construção de um conjunto de árvores de decisão aleatórias (*iTrees*). Em cada nó da árvore, uma variável é selecionada aleatoriamente, seguida pela escolha de um ponto de corte arbitrário entre os valores mínimo e máximo dessa variável. Como as anomalias possuem atributos quantitativos atípicos ou frequências reduzidas, elas exigem poucas partições para serem completamente isoladas nas folhas mais rasas da árvore (Liu; Ting; Zhou, 2008).

Matematicamente, a pontuação de anomalia $s(x, n)$ de uma observação x em uma base de tamanho n é definida pela Equação 5.2:

$$s(x, n) = 2^{-\frac{E(h(x))}{c(n)}} \quad (5.2)$$

Em que $E(h(x))$ representa a média do comprimento do caminho de busca de x ao longo da floresta de árvores, e $c(n)$ é a extensão média de busca sem sucesso em uma árvore binária de busca construída com n nós. Quanto mais próximo de 1 for o escore s , maior é a probabilidade de a observação constituir uma anomalia isolada (Liu; Ting; Zhou, 2008). A grande vantagem do *Isolation Forest* em relação a outros algoritmos não supervisionados reside na sua baixa complexidade computacional e linearidade ($O(n \log n)$), tornando-o altamente eficiente para o processamento de bases populacionais volumosas como a do Portal da Transparência do Acre (Liu; Ting; Zhou, 2008; Pereira, 2025).

5.4.2 Local Outlier Factor (LOF)

Desenvolvido por Breunig *et al.* (2000), o *Local Outlier Factor* (LOF) é um algoritmo de detecção de anomalias baseado em densidade local que emprega a técnica dos k -vizinhos mais próximos (k -NN) (Breunig *et al.*, 2000). O pilar conceitual do LOF fundamenta-se na premissa de que a anomalia não deve ser definida apenas pela sua distância global ao centro da base, mas sim pelo seu grau de isolamento relativo em relação à densidade da sua vizinhança local (Breunig *et al.*, 2000; Vieira *et al.*, 2019).

Para cada ponto p da base, o algoritmo calcula a sua densidade de acessibilidade local (*local reachability density* – $lrd_k(p)$), comparando-a subsequentemente com a densidade de acessibilidade média dos seus k -vizinhos mais próximos. A razão entre essas densidades determina o fator de *outlier* local ($LOF_k(p)$), expresso pela Equação 5.3:

$$LOF_k(p) = \frac{\sum_{o \in N_k(p)} \frac{lrd_k(o)}{lrd_k(p)}}{|N_k(p)|} \quad (5.3)$$

Em que $N_k(p)$ representa o conjunto dos k -vizinhos mais próximos do ponto p . A interpretação do indicador LOF ocorre da seguinte forma (Breunig *et al.*, 2000):

- $LOF \approx 1$: Indica que o ponto possui densidade similar à de seus vizinhos, pertencendo a um agrupamento denso e homogêneo (padrão normal);
- $LOF < 1$: Representa observações localizadas no interior de agrupamentos muito densos;
- $LOF \gg 1$: Sinaliza que a densidade do ponto é significativamente menor do que a de seus vizinhos, caracterizando-o como um *outlier* local atípico.

A aplicação do LOF em dados da administração pública demonstra grande utilidade para identificar municípios ou órgãos cujos padrões de despesa destoam substancialmente de seus pares comparáveis (como demonstrado por Vieira, 2019 ao analisar repasses do SICONFI) (Vieira *et al.*, 2019). A integração combinada do *Isolation Forest* e do *Local Outlier Factor*

permite capturar tanto anomalias globais quanto desvios locais de densidade na base orçamentária do Estado do Acre (Breunig *et al.*, 2000; Liu; Ting; Zhou, 2008).

5.5 Mineração de Texto em Históricos Contábeis (NLP e DBSCAN)

Enquanto os campos numéricos e cadastrais das despesas públicas possibilitam análises quantitativas diretas, a real intenção e o detalhamento das contratações governamentais residem no campo descritivo de texto livre, denominado **histórico do empenho/pagamento**. O tratamento analítico dessa variável impõe desafios adicionais à Ciência de Dados devido à ausência de padronização, presença de abreviações informais, ruídos de digitação e variações sintáticas (Goldschmidt, 2005; Pereira, 2025).

Para converter esse conteúdo textual não estruturado em representações numéricas computáveis, utiliza-se a técnica de vetorização por Frequência do Termo–Inverso da Frequência nos Documentos (*Term Frequency–Inverse Document Frequency* – TF-IDF). A métrica TF-IDF pondera a relevância de uma palavra t em um histórico d pertencente a um conjunto de documentos D , penalizando termos excessivamente genéricos (como "referente", "pago", "aquisição") e valorizando termos discriminativos (como nomes de insumos, medicamentos ou serviços específicos) (Goldschmidt, 2005). Matematicamente, a ponderação é calculada pela Equação 5.4:

$$\text{TF-IDF}(t, d, D) = \text{TF}(t, d) \times \log \left(\frac{|D|}{|\{d \in D : t \in d\}|} \right) \quad (5.4)$$

Uma vez obtida a matriz esparsa de vetores TF-IDF, emprega-se o algoritmo de agrupamento baseado em densidade **DBSCAN** (*Density-Based Spatial Clustering of Applications with Noise*), proposto por Ester *et al.* (1996) (Ester *et al.*, 1996). Ao contrário de algoritmos de particionamento como o K-Means, o DBSCAN oferece três vantagens cruciais para a análise de despesas públicas (Ester *et al.*, 1996; Vieira *et al.*, 2019):

1. Não exige a definição prévia do número de agrupamentos (k);
2. Identifica agrupamentos de formatos geométricos arbitrários no espaço vetorial;
3. Isola autonomamente pontos de ruído (*noise*), isto é, históricos atípicos que não possuem densidade similar a nenhum grupo.

O DBSCAN é parametrizado pelo raio de vizinhança (ϵ) e pelo número mínimo de pontos (*MinPts*). Na auditoria contábil, a integração de TF-IDF com DBSCAN permite agrupar históricos de empenho com redações semanticamente equivalentes, viabilizando a identificação de variações atípicas de preços unitários em contratos similares, bem como a varredura automatizada de fracionamentos de licitação (*smurfing*) (Nunes *et al.*, 2021).

5.6 Trabalhos Relacionados

A consolidação da Ciência de Dados Forense aplicada ao setor público é evidenciada por um conjunto crescente de estudos que investigam a detecção de anomalias em bases orçamentárias brasileiras. O Quadro 1 sintetiza os principais trabalhos correlatos da literatura, destacando seus objetivos, métodos e a lacuna preenchida pelo presente TCC.

Tabela 1 – Quadro comparativo dos trabalhos relacionados na literatura nacional.

Autor / Documento	Domínio / Escopo	Metodologia Computacional	Diferencial / Foco Principal
Cavalcanti (2014) (Cavalcanti, 2014)	Cartão Corporativo (CPGF) – Governo Federal (2013)	Lei de Benford, Teste Z-Score, Qui-Quadrado e DAM	Validação jurídica e discricionariedade do uso de filtros estatísticos em auditorias do CPGF.
Cella (2018) (Cella, 2018)	Despesas Públicas Municipais – Estado de Goiás	Lei de Newcomb-Benford e Testes de Aderência Estatística	Avaliação de conformidade em contas municipais e identificação de distorções em dígitos iniciais.
Vieira (2019) (Vieira <i>et al.</i> , 2019)	Gastos Municipais – SICONFI / DATASUS / FIRJAN	Algoritmo LOF (<i>Local Outlier Factor</i>) e Framework KDD	Unificação de bases fiscais e indicadores sociais para redução de falsos positivos em prefeituras.
Asensi (2020) (Asensi; Santos; Costa, 2020)	Despesas Públicas Municipais	Mineração de Dados e Parametrização de Gastos	Parametrização de custos públicos e mapeamento de padrões atípicos de execução orçamentária.
Nunes <i>et al.</i> (2021) (Nunes <i>et al.</i> , 2021)	Cartão Corporativo (CPGF) – Exercícios 2018–2019	K-Means, Agrupamento Hierárquico e Redes Complexas	Detecção de anomalias sem rotulagem prévia em gastos federais via topologia de redes.
Pereira (2025) (Pereira, 2025)	Desembolsos Extraorçamentários – Estado de Goiás (2024)	Pipeline KDD, Lei de Benford, Z-Score e Qui-Quadrado em Python	Validação populacional (100% da base) do desvio no Dígito 1 como filtro inicial de triagem.
Estudo de Controle Interno Estadual (Interno, 2023)	Gestão e Controle Interno nos Estados Brasileiros	Levantamento de Práticas e Ciência de Dados	Mapeamento do nível de maturidade computacional e uso de dados abertos nas controladorias estaduais.
Estudo de CD em Dados Públicos (Silva; Pereira, 2023)	Bases Abertas de Despesas Governamentais	Mineração Exploratória e Estatística Descritiva	Aplicação de pipelines de limpeza e transformação sobre bases orçamentárias heterogêneas.
Análise de Anomalias Administrativas (Souza; Nascimento, 2024)	Dados de Execução Orçamentária e Financeira	Detecção Estatística de Atipicidades	Mapeamento de desvios em empenhos e liquidações na administração pública subnacional.

Fonte: Elaborado pelo autor com base na literatura correlata (2026).

A análise conjunta dos nove trabalhos relacionados sintetizados no Quadro 1 evidencia uma evolução metodológica clara: enquanto os estudos seminais (como Cavalcanti, 2014 e Cella, 2018) focaram prioritariamente na validação da estatística descritiva de Benford, pesquisas

subsequentes avançaram para a integração de algoritmos não supervisionados de densidade (Vieira, 2019) e topologia de redes (Nunes *et al.*, 2021), culminando na adoção de pipelines populacionais integrais em ambiente Python (Pereira, 2025) e no diagnóstico da maturidade do controle interno estadual.

A despeito desse panorama consolidado, constata-se uma lacuna no que tange à integração conjunta dessas técnicas (Benford, ISO, LOF e NLP) aplicada a bases populacionais subnacionais da Amazônia Sul-Occidental, cenário que fundamenta a oportunidade e o ineditismo do presente estudo de caso no Estado do Acre.

6 PROCEDIMENTOS METODOLÓGICOS

7 RESULTADOS

7.1 PIPELINE KDD E COBERTURA POPULACIONAL

- Processamento automatizado de 100% da base de dados do Portal da Transparência do Acre via scripts em Python.
- Análise abrangente contemplando mais de 429 mil registros de despesas públicas no período entre 2020 e 2025.

7.2 FILTRO ESTATÍSTICO DE BENFORD E Z-SCORE

7.2.1 Diagnóstico de Falsos Positivos

- Detecção de anomalias estatísticas expressivas localizadas nos Dígitos 4 ($Z = +9,97$) e 7 ($Z = +25,66$).
- A análise qualitativa de texto (NLP) revelou que esses picos não representavam fraudes mascaradas.
- Constatou-se a presença de "falsos positivos" causados diretamente por padronizações normativas, especificamente os valores tabelados de diárias civis e militares oriundos do Fundo Penitenciário.

7.3 REDES DE GRAFOS E OLIGOPÓLIOS ESTRUTURAIS

- Mapeamento de matrizes de co-ocorrência utilizando as bibliotecas *NetworkX* e *PyVis*.
- Evidenciou-se uma altíssima centralização de mercado na administração estadual.
- Identificação de um núcleo reduzido de empresas atuando simultaneamente em até 28 secretarias de estado, viabilizado pelo uso intensivo de Atas de Registro de Preço (prática de "Caronas").

7.4 ALGORITMO DE SMURFING E O ESTUDO DE CASO 4HEALTH

- O algoritmo de varredura projetado para detectar dispensa de licitação identificou um total de R\$ 12,07 milhões distribuídos em 9 repasses.

- Destinatária dos recursos: 4Health Serviços Médicos Ltda, através do Fundo Estadual de Saúde (FUNDES/SESACRE).
- A inspeção dos históricos contábeis, baseada nos processos SEI e nos Contratos 677/2023 e 862/2024, revelou a prestação continuada de serviços de anestesiologia via dispensa de licitação ao longo de 3 anos consecutivos (2023 a 2025).

7.5 DIAGNÓSTICO FORENSE

- O modelo analítico demonstrou capacidade robusta de extrapolar a detecção do fracionamento comum de pequeno valor (*smurfing*).
- Exposição de um cenário caracterizado por "emergência fabricada" ou inércia administrativa.
- O contexto anômalo detectado é respaldado pela escassez crônica de médicos anesthesiologistas na região e pelos sucessivos decretos de emergência climática emitidos no Acre.

8 CRONOGRAMA

O processo de escrita desta monografia seguirá o cronograma explicitado no Quadro 1.

Mês	Data	Dias	Atividade
Novembro	03-11-2025 até 17-11-2025	15	Escrita do Capítulo 1 - Introdução .
Novembro	18-11-2025 até 30-11-2025	13	Início da escrita do Capítulo 2 - Fundamentação Teórica .
Dezembro	01-12-2025 até 15-12-2025	15	Conclusão da escrita do Capítulo 2 - Fundamentação Teórica .
Dezembro	16-12-2025 até 23-12-2025	8	Etapa 1 e 2 (Planejamento e Identificação): Início da busca/seleção de estudos e redação do Capítulo 3 - Metodologia .
Janeiro	03-01-2026 até 12-01-2026	10	Conclusão da Etapa 1 e 2 e da redação do Capítulo 3 .
Janeiro	13-01-2026 até 31-01-2026	19	Etapa 3 e 4 (Extração e Visualização): Análise dos dados e início da redação do Capítulo 4 - Resultados .
Fevereiro	01-02-2026 até 06-02-2026	6	Conclusão da redação do Capítulo 4 - Resultados .
Fevereiro	07-02-2026 até 15-02-2026	9	Etapa 5 (Relatório): Redação do Capítulo 5 - Considerações Finais e entrega da versão completa para a orientadora.
Fevereiro	16-02-2026 até 28-02-2026	13	Período de revisão e aplicação dos ajustes finais.
Março	A definir em 03/2026	-	Preparação da apresentação e Defesa do Trabalho de Conclusão de Curso .

Fonte: Elaboração própria.

Quadro 1: Cronograma de execução da pesquisa.

REFERÊNCIAS

- ASENSI, F.; SANTOS, A.; COSTA, B. Mineração de dados aplicada à detecção de padrões atípicos em despesas públicas municipais. **Revista de Gestão Pública e Transparência**, v. 8, n. 2, p. 88–113, 2020.
- BREUNIG, M. M. *et al.* Lof: Identifying density-based local outliers. **ACM SIGMOD Record**, v. 29, n. 2, p. 93–104, 2000.
- CAVALCANTI, G. H. d. V. **Aplicação da Lei de Newcomb-Benford na Identificação de Irregularidades: o exemplo dos gastos com cartões de pagamento do governo federal – CPGF**. Tese (Doutorado) — Controladoria-Geral da União (CGU), Brasília, 2014.
- CELLA, R. N. Aplicação da lei de newcomb-benford na análise de despesas municipais: Evidências de distorções em dígitos iniciais. **Revista Brasileira de Finanças Públicas**, v. 12, n. 1, p. 45–68, 2018.
- ESTER, M. *et al.* A density-based algorithm for discovering clusters in large spatial databases with noise. In: **Proceedings of the Second International Conference on Knowledge Discovery and Data Mining**. [S.l.]: AAAI Press, 1996.
- GOLDSCHMIDT, R. **Data Mining e Gestão Pública**. São Paulo: Editora XYZ, 2005.
- INTERNO, S. de Estado da Administração e C. **Diagnóstico de Maturidade em Controle Interno e Uso de Dados Abertos em Entes Estaduais Brasileiros**. [S.l.], 2023.
- LIU, F. T.; TING, K. M.; ZHOU, Z.-H. Isolation forest. In: **Proceedings of the 8th IEEE International Conference on Data Mining**. Pisa: IEEE, 2008.
- NIGRINI, M. J. **Benford's Law: Applications for Forensic Accounting, Auditing, and Fraud Detection**. New Jersey: Wiley, 2012.
- NUNES, B. O. *et al.* Anomaly detection in brazilian federal government purchase cards through unsupervised learning techniques. **IEEE Access**, v. 9, p. 1–15, 2021.
- PEREIRA, J. P. T. **Ciência de Dados Aplicada na Detecção de Fraude em Demonstrações Financeiras**. Goiânia: [s.n.], 2025. Trabalho de Conclusão de Curso – PUC Goiás.
- SILVA, A.; PEREIRA, J. **Pipeline de Ciência de Dados em Bases Abertas de Despesas Governamentais**. 2023. Relatório Técnico Interno.
- SOUZA, M.; NASCIMENTO, P. **Análise de Anomalias Administrativas em Despesas de Execução Orçamentária**. 2024. Nota Técnica de Monitoramento Governamental.
- VIEIRA, R. *et al.* Detecção de anomalias em gastos públicos por meio de técnicas de aprendizado não supervisionado. **Revista de Informática Aplicada**, v. 15, n. 2, p. 120–138, 2019.