



Universidade Federal do Acre

Guilherme de Jesus Carvalho

**Ciência de Dados Aplicada Na Detecção de Anomalias em
Portais de Transparências: Um Estudo de Caso do Governo do
Estado do Acre**

Rio Branco
2026

Guilherme de Jesus Carvalho

**Ciência de Dados Aplicada Na Detecção de Anomalias em
Portais de Transparências: Um Estudo de Caso do Governo do
Estado do Acre**

Universidade Federal do Acre

Orientador: Prof. Dra. Laura Costa Sarkis
Coorientador: Prof. Dra. Lorena Caceres Tomaya

Rio Branco
2026

LISTA DE ILUSTRAÇÕES

Figura 1 – Interface do Portal da Transparência evidenciando a disponibilização de microdados brutos de despesas governamentais.	8
Figura 2 – Fluxograma geral da esteira de Ciência de Dados Forense baseada no ciclo KDD.	24

LISTA DE QUADROS

1	Cronograma de execução da pesquisa.	32
*		

SUMÁRIO

1	APRESENTAÇÃO	6
2	PROBLEMA DA PESQUISA	7
3	OBJETIVOS DA PESQUISA	10
3.1	Objetivo Geral	10
3.2	Objetivos Específicos	10
4	JUSTIFICATIVA DA PESQUISA	12
4.1	Relevância Social e Prática	12
4.2	Relevância Científica e Acadêmica	12
4.3	Relevância Técnica e Tecnológica	13
4.4	Viabilidade da Pesquisa	13
5	FUNDAMENTAÇÃO TEÓRICA	15
5.1	Transparência Pública, Dados Abertos e Controle Social	15
5.2	O Processo KDD (<i>Knowledge Discovery in Databases</i>) e a Análise Populacional	16
5.3	Filtros Estatísticos de Distribuição: Lei de Benford e Z-Score	17
5.4	Aprendizado de Máquina Não Supervisionado na Detecção de Anomalias	18
5.4.1	<i>Isolation Forest</i> (ISO)	18
5.4.2	<i>Local Outlier Factor</i> (LOF)	19
5.5	Mineração de Texto em Históricos Contábeis (NLP e DBSCAN)	20
5.6	Trabalhos Relacionados	21
6	PROCEDIMENTOS METODOLÓGICOS	23
6.1	Estrutura do Pipeline Analítico	23
6.2	Caracterização da Pesquisa	24
6.3	Fonte de Dados, Recorte Populacional e Atributos	25
6.3.1	Origem e Acesso aos Dados	25
6.3.2	Recorte Populacional e Temporal	25
6.3.3	Dicionário de Atributos e Seleção de Variáveis	26
6.4	A Esteira de Processamento de Dados (Pipeline KDD)	26
6.4.1	Pré-processamento e Higienização de Dados (<i>Data Cleaning</i>)	27
6.4.2	Engenharia de Atributos (<i>Feature Engineering</i>)	27
6.4.3	Módulo Estatístico Paramétrico: Lei de Benford e Z-Score	28
6.4.4	Módulo de Aprendizado de Máquina Não Supervisionado: ISO e LOF	28
6.4.5	Módulo de NLP e Agrupamento Semântico (TF-IDF + DBSCAN)	28
6.5	Análise de Redes Complexas e Topologia de Grafos	29
6.5.1	Modelagem de Rede Bipartida e Projeção	29
6.5.2	Métricas de Centralidade e Mapeamento de Oligopólios	29
6.6	Ambiente Computacional e Ferramentas	30

6.7	Escore Integrado de Risco e Validação dos Resultados	30
6.7.1	Composição do Escore Integrado	30
6.7.2	Validação Qualitativa e Filtro de Falsos Positivos	31
7	CRONOGRAMA	32
8	ESBOÇO DOS CAPÍTULOS E SEÇÕES	33
Referências		36

1 APRESENTAÇÃO

A crescente digitalização da administração pública e a consolidação dos portais de transparência governamentais têm disponibilizado volumes massivos de microdados sobre a execução orçamentária e financeira do setor público no Brasil. Contudo, a simples publicação bruta desses dados em tabelas e relatórios nem sempre se traduz em conhecimento acessível para a sociedade ou em insights estratégicos para a Gestão Pública, dada a elevada complexidade e assimetria das transações financeiras (Cavalcanti, 2014; Pereira, 2025). Neste cenário, a Ciência de Dados e o processo de Descoberta de Conhecimento em Bases de Dados (*Knowledge Discovery in Databases* – KDD) emergem como campos interdisciplinares fundamentais para transformar grandes volumes de dados não estruturados em conhecimento útil e interpretável (Goldschmidt, 2005). Em vez de recorrer a técnicas tradicionais de amostragem restrita, a aplicação de algoritmos computacionais permite o processamento populacional integral (100% dos registros), garantindo uma análise holística da dinâmica dos gastos públicos (Pereira, 2025). Como a base de dados do Portal da Transparência é composta por dados abertos não rotulados (*unlabelled data*) — isto é, sem a indicação prévia do que constitui um lançamento regular ou uma anomalia —, a aplicação de modelos de aprendizado de máquina supervisionado (como SVM e algoritmos de classificação) torna-se inviável na prática. Por essa razão, este projeto de pesquisa adota rigorosamente a abordagem de **Aprendizado de Máquina Não Supervisionado** (*Unsupervised Machine Learning*) e estatística descritiva, permitindo a descoberta de padrões ocultos e agrupamentos sem a necessidade de um gabarito prévio (Nunes *et al.*, 2021). O presente projeto de Trabalho de Conclusão de Curso (TCC) propõe o desenvolvimento de um pipeline computacional aplicado sobre a base populacional de despesas do Portal da Transparência do Estado do Acre, englobando mais de 429 mil registros financeiros referentes ao período de 2020 a 2025. O objetivo central deste estudo não reside na acusação criminal ou auditoria investigativa de ilícitos, mas sim no uso da Ciência de Dados para mapear, visualizar e compreender os fenômenos socioadministrativos reais que moldam a gestão pública acreana.

2 PROBLEMA DA PESQUISA

A garantia da transparência pública e o fortalecimento do controle social no Brasil foram impulsionados pela promulgação da Lei de Acesso à Informação (Lei nº 12.527/2011) e pela Lei de Responsabilidade Fiscal (Lei Complementar nº 101/2000). Esses marcos normativos obrigaram os entes federativos a disponibilizarem, em meios eletrônicos, informações detalhadas sobre a execução orçamentária em tempo real. No entanto, os portais de transparência governamentais abrigam bases dinâmicas com milhões de lançamentos contínuos acumulados ao longo dos anos. Essa escala massiva frequentemente resulta no fenômeno da "opacidade por excesso" (*information overload*), no qual a simples publicação bruta de dados não estruturados cria barreiras para a interpretação pública (Cavalcanti, 2014; Pereira, 2025). No âmbito do controle institucional, órgãos formais como a Controladoria-Geral da União (CGU) e os Tribunais de Contas Estaduais (TCE) dispõem de auditores especializados e sistemas proprietários de inteligência para fiscalização interna. Contudo, essas ferramentas restritas não estão acessíveis à sociedade civil, a jornalistas de dados e à comunidade acadêmica, que dependem exclusivamente dos microdados abertos publicados nos portais. Para este público, a análise manual de bases massivas mostra-se inviável, demandando metodologias abertas de Ciência de Dados para a automação da triagem e extração de conhecimento (Nunes *et al.*, 2021). No contexto da pesquisa "**Ciência de Dados Aplicada na Detecção de Anomalias em Portais de Transparência: Um Estudo de Caso do Governo do Estado do Acre**", a análise foca no recorte populacional de mais de 429 mil registros financeiros referentes ao período de 2020 a 2025. A partir desse ecossistema de dados abertos, emergem desafios centrais de Ciência de Dados e Aprendizado de Máquina (*Machine Learning*):

1. **Ausência de Rotulagem (*Unlabelled Data*):** Os dados abertos dos portais de transparência não possuem rotulação prévia (*ground truth*) que identifique empenhos normais ou anômalos. A inexistência de um gabarito inviabiliza o uso direto de modelos supervisionados (como SVM e Árvores de Decisão), exigindo o emprego de algoritmos de **Aprendizado Não Supervisionado** (*Isolation Forest – ISO, Local Outlier Factor – LOF e DBSCAN*) aliados a testes de distribuição estatística (Lei de Benford e Z-Score) (Nunes *et al.*, 2021; Goldschmidt, 2005);
2. **Complexidade Normativa e Falsos Positivos:** O uso isolado de testes estatísticos pode gerar falsos positivos ao identificar concentrações de pagamentos perfeitamente legítimos, mas tabelados por decretos (como diárias e auxílios operacionais). A superação desse gargalo exige a integração de técnicas de Processamento de Linguagem Natural (NLP) sobre os históricos contábeis para contextualizar o texto livre das despesas (Cavalcanti, 2014);

3. **Ineditismo e Lacuna de Pesquisa na Região Acreana:** A literatura nacional sobre Ciência de Dados e transparência pública concentra suas aplicações predominantemente na esfera federal ou em estados do Sul e Sudeste (Cavalcanti, 2014; Nunes *et al.*, 2021). O levantamento exploratório confirma a escassez de estudos computacionais dedicados à infraestrutura e aos microdados do Portal da Transparência do Estado do Acre, evidenciando uma lacuna científica regional que justifica a realização deste estudo de caso.

Um dos principais obstáculos para o controle social moderno reside no fenômeno denominado na literatura como **"Opacidade por Excesso"** (*Information Overload*). Diferentemente do cenário histórico de escassez ou sigilo de dados públicos, o cenário contemporâneo é marcado pela publicação de tabelas com centenas de milhares de registros tabulares sem qualquer tipo de agregação analítica ou filtragem preditiva de risco (Cavalcanti, 2014; Nunes *et al.*, 2021). A Figura 1 exemplifica essa problemática a partir da interface de consulta do Portal da Transparência.

Ano	Órgão	Nome do Fornecedor	CNPJ/CPF	Classe fornecedor
2025	MINISTÉRIO PÚBLICO	AVANTI SOLUCOES IMOBILIARIAS LTDA	22.244.806/0001-68	ALUGUEIS
2025	SECRETARIA DE ESTADO DA FAZENDA - SEFAZ	PREFEITURA MUNICIPAL DE BRASILEIA	04.508.933/0001-45	TRANS.F.A MUNICIPIOS - IPVA.
2025	MINISTÉRIO PÚBLICO	MINISTERIO DA FAZENDA	00.394.460/0003-03	ENCARGOS SOCIAIS
2025	MINISTÉRIO PÚBLICO	PLUS TERCEIRIZAÇÃO LTDA	27.072.369/0001-66	PRESTADOR DE SERVIÇO
2025	SECRETARIA DE ESTADO DA FAZENDA - SEFAZ	PREFEITURA MUNICIPAL DE ACRELANDIA	84.306.737/0001-27	TRANS.F.A MUNICIPIOS - IPVA.
2025	SECRETARIA DE ESTADO DA FAZENDA - SEFAZ	PREFEITURA MUNICIPAL DE ASSIS BRASIL	04.045.993/0001-79	TRANS.F.A MUNICIPIOS - IPVA.
2025	MINISTÉRIO PÚBLICO	BANCO DO BRASIL S/A	00.000.000/5112-85	TARIFAS
2025	MINISTÉRIO PÚBLICO	BANCO BRADESCO S/A	60.746.948/0001-12	REGULARIZAÇÕES
2025	MINISTÉRIO PÚBLICO	FOPAG MINISTERIO PUBLICO	04.034.450/0001-56	FOLHA DE PAGAMENTO
2025	SECRETARIA DE ESTADO DA FAZENDA - SEFAZ	PREFEITURA MUN DE BUJARI	84.306.620/0001-43	TRANS.F.A MUNICIPIOS - IPVA.

Mostrando de 1 até 10 de 92.326 registros

Anterior 1 2 3 4 5 ... 9233 Próximo

Dados atualizados em: 23/09/2026

Fonte: Sistema Integrado de Contabilidade, Administração Financeira e Orçamentária do Estado do Acre - SICAF

Figura 1 – Interface do Portal da Transparência evidenciando a disponibilização de microdados brutos de despesas governamentais.

Fonte: Portal da Transparência do Governo (2026).

Como observado na Figura 1, a consulta disponibiliza milhares de linhas contendo códigos orçamentários, favorecidos e históricos contábeis preenchidos em texto livre. Para um cidadão ou analista humano, a tentativa de identificar manualmente fracionamentos ilícitos de licitação (*smurfing*), superfaturamentos ou concentrações de mercado em uma base com mais de 429 mil registros (como no caso do Estado do Acre entre 2020 e 2025) torna-se uma tarefa operacionalmente inviável.

Nesse contexto, justifica-se a aplicação da **Ciência de Dados Forense** e do aprendizado de máquina não supervisionado. Em vez de exigir que o usuário navegue manualmente por tabelas extensas, a construção de um pipeline computacional automatizado atua como uma camada de

inteligência analítica, capaz de triar a base populacional integral, reduzir o universo amostral de risco e apresentar sinalizadores preditivos (*red flags*) para priorizar a investigação humana.

Diante dessa problemática, formula-se a seguinte **Pergunta de Pesquisa** que orienta este trabalho:

Em que medida a aplicação de um pipeline de Ciência de Dados baseado em Aprendizado Não Supervisionado (Isolation Forest, Local Outlier Factor e DBSCAN), testes estatísticos descritivos (Lei de Benford e Z-Score) e Processamento de Linguagem Natural permite identificar, filtrar e interpretar anomalias e padrões socioadministrativos nos microdados abertos do Portal da Transparência do Estado do Acre (2020–2025), sem a necessidade de dados previamente rotulados?

3 OBJETIVOS DA PESQUISA

Com o intuito de responder à pergunta de pesquisa formulada e viabilizar a análise computacional dos microdados abertos do setor público, este capítulo delimita o objetivo geral e os objetivos específicos que norteiam o desenvolvimento deste trabalho.

3.1 Objetivo Geral

Desenvolver e avaliar uma metodologia baseada em técnicas de Ciência de Dados e Aprendizado de Máquina para detectar padrões anômalos nas despesas públicas registradas no Portal da Transparência e relacionadas ao Estado do Acre, identificando transações ou grupos de transações que apresentem comportamento atípico em relação aos padrões históricos de execução da despesa.

3.2 Objetivos Específicos

Para o alcance do objetivo geral, estabelecem-se os seguintes objetivos específicos:

1. Coletar, integrar e organizar os dados de despesas públicas do Portal da Transparência do Acre, construindo o subconjunto de dados do estudo;
2. Caracterizar estatisticamente o comportamento das despesas, avaliando sua distribuição, concentração, variabilidade e evolução temporal segundo órgão, unidade gestora, favorecido e natureza da despesa;
3. Mapear indicadores e atributos que expressem padrões potencialmente anômalos nas despesas, considerando valor, frequência, recorrência, concentração por favorecido e variação temporal;
4. Aplicar métodos de análise não supervisionada para identificar observações ou padrões anômalos nas despesas analisadas;
5. Comparar o desempenho e a concordância entre diferentes procedimentos de detecção de anomalias, identificando despesas classificadas como atípicas por uma ou mais abordagens;
6. Investigar a distribuição das anomalias identificadas segundo órgãos, favorecidos, categorias de despesa e períodos de execução, buscando reconhecer padrões socioadministrativos recorrentes;
7. Desenvolver um escore ou classificação de prioridade das observações detectadas, de forma a auxiliar na seleção das despesas que mereçam atenção analítica;

8. Avaliar a aplicabilidade da metodologia proposta como instrumento complementar de transparência e controle dos gastos públicos.

4 JUSTIFICATIVA DA PESQUISA

A relevância deste Trabalho de Conclusão de Curso fundamenta-se na interseção entre a Ciência de Dados, a Ciência da Informação e a Gestão Pública, desdobrando-se nas dimensões social, científica, técnica e prática.

4.1 Relevância Social e Prática

A consolidação do princípio constitucional da publicidade e os avanços promovidos pela Lei de Acesso à Informação (Lei nº 12.527/2011) garantiram o direito fundamental de acesso aos dados orçamentários do setor público brasileiro. Contudo, a simples publicação de relatórios contábeis extensos e dados brutos nos portais de transparência não assegura, por si só, a efetividade da transparência pública. Na prática, a sociedade civil, jornalistas de dados e a comunidade acadêmica enfrentam o fenômeno da "opacidade por excesso" (*information overload*), no qual o volume massivo e desestruturado de informações impede a compreensão direta sobre como os recursos públicos estão sendo alocados (Cavalcanti, 2014; Pereira, 2025).

Nesse contexto, a aplicação de técnicas de Ciência de Dados atua como um instrumento de democratização da informação e fortalecimento do controle social. Ao transformar microdados financeiros brutos em representações analíticas compreensíveis e padrões interpretáveis, a pesquisa contribui para reduzir a assimetria de informação entre a administração governamental e o cidadão. Além disso, no âmbito prático da gestão pública, o desenvolvimento de mecanismos abertos de triagem automatizada permite identificar gargalos normativos e padrões atípicos de execução orçamentária, fornecendo subsídios para o aprimoramento da eficiência administrativa e do planejamento de políticas públicas no Estado do Acre.

4.2 Relevância Científica e Acadêmica

Apesar da expansão de pesquisas dedicadas ao uso de técnicas computacionais e estatísticas na fiscalização de gastos públicos no Brasil, observa-se que a literatura científica nacional concentra suas aplicações predominantemente em dados federais — como o Cartão de Pagamento do Governo Federal (CPGF) e o SICONFI — ou em grandes metrópoles das regiões Sul e Sudeste (Cavalcanti, 2014; Nunes *et al.*, 2021). Em contrapartida, o ecossistema de dados abertos dos entes subnacionais da Região Norte, em especial do Estado do Acre, permanece subexplorado pela pesquisa em Ciência de Dados e Sistemas de Informação.

O ineditismo regional desta pesquisa reside justamente na aplicação e validação de um pipeline computacional não supervisionado sobre a base populacional de despesas do Poder Executivo do Estado do Acre. Do ponto de vista científico, o estudo preenche uma lacuna relevante

na literatura ao investigar como modelos de detecção de anomalias e testes estatísticos de distribuição comportam-se diante das especificidades orçamentárias, normativas e fornecedoras de uma unidade federativa da Amazônia Sul-Occidental. Assim, o trabalho amplia a validade externa das metodologias de Ciência de Dados aplicadas à transparência pública, fornecendo um arcabouço metodológico reprodutível e replicável para outros estados com dinâmicas administrativas semelhantes (Pereira, 2025).

4.3 Relevância Técnica e Tecnológica

Do ponto de vista tecnológico e computacional, a justificativa deste trabalho assenta-se na superação dos limites impostos pelas abordagens analógicas e amostrais tradicionais de fiscalização. A análise populacional integral — que abrange 100% dos mais de 429 mil registros do recorte temporal estipulado — garante que nenhum evento atípico seja omitido por viés de seleção ou corte arbitrário de dados, aumentando a confiabilidade da triagem (Pereira, 2025).

Ademais, a arquitetura metodológica proposta responde a um desafio técnico central na mineração de dados abertos governamentais: a ausência de rótulos prévios (*unlabelled data*). Ao integrar modelos de Aprendizado de Máquina Não Supervisionado (*Isolation Forest*, *Local Outlier Factor* e *DBSCAN*) a testes estatísticos de distribuição (Lei de Benford e Z-Score) e técnicas de Processamento de Linguagem Natural (NLP), a pesquisa estabelece um pipeline computacional capaz de identificar anomalias estruturais e isolar falsos positivos decorrentes de regras normativas da administração pública (Cavalcanti, 2014; Nunes *et al.*, 2021; Goldschmidt, 2005). Trata-se de uma solução tecnológica reprodutível e orientada à automação do processo de triagem contábil.

4.4 Viabilidade da Pesquisa

A viabilidade técnica, operacional e temporal deste projeto de pesquisa é plenamente assegurada pela conjugação de três fatores fundamentais: a disponibilidade de dados públicos abertos, o uso de ecossistemas computacionais de código aberto (*open-source*) e o avanço prévio do pipeline de dados.

Em primeiro lugar, a garantia de acesso aos microdados é respaldada pela legislação nacional de transparência (Lei nº 12.527/2011), uma vez que a totalidade das informações necessárias provém do Portal da Transparência do Estado do Acre, um ecossistema de dados abertos e de livre acesso que não impõe barreiras legais ou restrições de sigilo à extração de dados orçamentários.

Em segundo lugar, a exequibilidade computacional do trabalho apoia-se no uso da linguagem de programação Python e do seu ecossistema científico especializado (*pandas*, *numpy*, *scikit-learn*, *seaborn* e *networkx*). A opção por bibliotecas abertas e consolidadas elimina a dependência de licenças de software proprietário de alto custo e assegura a transparência e a reprodutibilidade integral do pipeline analítico (Pereira, 2025).

Por fim, a viabilidade cronológica é corroborada pela fase adiantada de preparação da base de dados. O processo de extração, limpeza e padronização do recorte populacional do Estado do Acre (2020–2025) — englobando mais de 429 mil registros financeiros — já se encontra concluído e validado em ambiente computacional. Esse amadurecimento técnico prévio mitiga riscos operacionais e assegura o cumprimento rigoroso do cronograma acadêmico estipulado para a execução do TCC.

5 FUNDAMENTAÇÃO TEÓRICA

Neste capítulo, apresentam-se os conceitos teóricos, modelos estatísticos, algoritmos computacionais e estudos correlatos que sustentam o desenvolvimento desta pesquisa.

5.1 Transparência Pública, Dados Abertos e Controle Social

A consolidação da transparência na administração pública brasileira é resultado de um processo histórico de aperfeiçoamento institucional e normativo, impulsionado pela promulgação da Lei de Responsabilidade Fiscal (Lei Complementar nº 101/2000) e pela Lei de Acesso à Informação (Lei nº 12.527/2011 – LAI). Esses marcos legalmente formalizaram a transição do modelo tradicional de sigilo administrativo para o paradigma da transparência ativa, no qual a publicidade passa a ser a regra geral e o sigilo, a exceção. Como decorrência, os entes federativos passaram a ser obrigados a disponibilizar, em portais de acesso público na internet, dados em tempo real sobre a execução orçamentária, financeira e operacional do setor público (Cavalcanti, 2014; Pereira, 2025).

Entretanto, a disponibilização bruta de dados nos portais de transparência governamentais expõe uma limitação crítica da transparência passiva e ativa não mediadas por ferramentas analíticas. Na literatura de Ciência da Informação e Gestão Pública, esse fenômeno é denominado "opacidade por excesso" (*information overload*). A publicação de tabelas com centenas de milhares de linhas, caracterizadas por descrições contábeis genéricas, ausência de metadados consolidados e falta de filtros inteligentes, cria uma barreira cognitiva para o cidadão comum, para jornalistas de dados e para a comunidade acadêmica (Cavalcanti, 2014; Nunes *et al.*, 2021). Embora o dado esteja formalmente acessível do ponto de vista jurídico, ele permanece ininteligível do ponto de vista prático e social.

A superação desse obstáculo é condição fundamental para o pleno exercício do controle social — mecanismo pelo qual a sociedade civil organizada participa da fiscalização e do acompanhamento da aplicação dos recursos públicos. Conforme destacado por Nunes *et al.* (2021), a efetividade da transparência governamental não reside na mera exibição técnica de dados de despesas, mas na transformação desses microdados em conhecimento estruturado, capaz de apontar autonomamente comportamentos atípicos e sinalizar padrões de alocação de recursos que exijam análise aprofundada (Nunes *et al.*, 2021).

Assim, o uso da Ciência de Dados e de sistemas computacionais abertos posiciona-se como uma ponte entre a disponibilidade legal do dado público e o seu aproveitamento prático pelo controle social, viabilizando a automação do processo de triagem sobre bases populacionais volumosas sem depender exclusivamente de auditorias analógicas ou de conhecimento especializado contábil (Nunes *et al.*, 2021; Pereira, 2025).

5.2 O Processo KDD (*Knowledge Discovery in Databases*) e a Análise Populacional

A extração de conhecimento a partir de grandes volumes de dados brutos exige a aplicação de metodologias estruturadas que orientem o tratamento da informação desde a sua coleta até a interpretação dos resultados. Na Ciência de Dados e na Mineração de Dados (*Data Mining*), o modelo conceitual amplamente aceito para essa finalidade é o processo de Descoberta de Conhecimento em Bases de Dados (*Knowledge Discovery in Databases* – KDD) (Goldschmidt, 2005; Pereira, 2025).

O ciclo KDD caracteriza-se por ser uma abordagem iterativa e sequencial, composta por cinco etapas fundamentais (Goldschmidt, 2005):

1. **Seleção:** Identificação e extração do conjunto de dados relevante (*dataset*) a partir das fontes operacionais brutas;
2. **Pré-processamento e Limpeza:** Higienização da base mediante o tratamento de valores ausentes, remoção de inconsistências, eliminação de duplicatas e correção de ruídos de formatação;
3. **Transformação:** Padronização dos tipos de dados, engenharia de atributos (*feature engineering*) e adequação das variáveis para os formatos exigidos pelos algoritmos analíticos;
4. **Mineração de Dados (*Data Mining*):** Aplicação de modelos estatísticos e algoritmos computacionais para o mapeamento e extração de padrões, agrupamentos e anomalias;
5. **Pós-processamento e Interpretação:** Validação, visualização e consolidação dos padrões descobertos em conhecimento útil e compreensível para o domínio de aplicação.

No contexto da gestão pública e do controle de gastos, a adoção do arcabouço KDD viabiliza uma mudança paradigmática fundamental: a transição das revisões analógicas baseadas em amostragem estatística restrita para a **Análise Populacional Integral (100% da base de dados)** (Pereira, 2025). As abordagens tradicionais de auditoria contábil frequentemente dependem de cortes amostrais arbitrários, o que cria pontos cegos e aumenta o risco de omissão de eventos atípicos pulverizados ou fracionados.

Por outro lado, o processamento da totalidade dos registros financeiros disponibilizados no Portal da Transparência elimina o viés de seleção amostral, assegurando que todas as transações passem pelo mesmo crivo analítico. Conforme demonstrado por Pereira (2025), a combinação da análise populacional com o pipeline KDD otimiza a alocação de esforços humanos de fiscalização, atuando como um filtro prévio automatizado que direciona a atenção dos analistas estritamente para as observações com elevados indicadores de atipicidade (Pereira, 2025).

5.3 Filtros Estatísticos de Distribuição: Lei de Benford e Z-Score

A análise da distribuição de frequências dos dígitos numéricos em bases de dados financeiras constitui uma técnica clássica da contabilidade forense e da Ciência de Dados para a identificação primária de anomalias estatísticas. O pilar fundamental dessa abordagem é a Lei de Newcomb-Benford (também conhecida como a Lei do Primeiro Dígito Significativo), descrita originalmente pelo astrônomo Simon Newcomb em 1881 e redescoberta pelo físico Frank Benford em 1938 (Nigrini, 2012; Pereira, 2025).

Diferentemente da intuição comum, que pressupõe uma distribuição uniforme na qual cada dígito de 1 a 9 teria 11,1% de probabilidade de ocupar a primeira posição em um número, a Lei de Benford demonstra que dados numéricos decorrentes de fenômenos naturais, sociais e econômicos não manipulados obedecem a uma distribuição logarítmica. Matematicamente, a probabilidade $P(d)$ de um número iniciar com o dígito $d \in \{1, 2, \dots, 9\}$ é dada pela Equação 5.1:

$$P(d) = \log_{10} \left(1 + \frac{1}{d} \right) \quad (5.1)$$

Conforme essa distribuição, o dígito 1 possui a maior probabilidade teórica de ocorrência (aproximadamente 30,1%), enquanto o dígito 9 apresenta a menor probabilidade (aproximadamente 4,6%). Quando dados financeiros sofrem manipulação humana deliberada ou ajustes artificiais — como o fracionamento de compras para burlar limites de licitação (*smurfing*) —, a distribuição natural dos dígitos tende a ser distorcida, gerando um desvio detectável frente à curva teórica (Nigrini, 2012; Cavalcanti, 2014).

Para avaliar a conformidade de uma base de dados pública frente à Lei de Benford, a literatura estabelece dois testes estatísticos complementares (Nigrini, 2012; Pereira, 2025):

1. **Teste Qui-Quadrado (χ^2):** Utilizado para testar a hipótese nula (H_0) de aderência global da base de dados, determinando se a distribuição observada dos dígitos desvia significativamente da distribuição teórica esperada em nível macro;
2. **Teste Z-Score:** Empregado para avaliar o desvio atômico e localizado de cada dígito individualmente, medindo quantos desvios-padrão a frequência observada dista da frequência teórica de Benford.

No entanto, a aplicação da Lei de Benford sobre microdados abertos da administração pública exige cautela analítica para evitar interpretações equivocadas. Como ressaltado por Cavalcanti (2014), picos de frequência observados em dígitos específicos (medidos por Z-Scores elevados) nem sempre sinalizam irregularidades ou fraudes intencionais. No setor público, desvios estatísticos severos frequentemente decorrem de regras de negócio rígidas e padronizações normativas — tais como concessões de diárias operacionais com valores fixados por decreto, reembolsos padronizados e tabelamento de auxílios. Portanto, o filtro estatístico de Benford deve

ser compreendido como um mecanismo descritivo de sinalização de atipicidade (*red flag*), cuja validação requer a integração com técnicas contextuais de mineração de texto e aprendizado de máquina (Cavalcanti, 2014; Nunes *et al.*, 2021).

5.4 Aprendizado de Máquina Não Supervisionado na Detecção de Anomalias

O Aprendizado de Máquina (*Machine Learning*) é a subárea da Inteligência Artificial dedicada ao desenvolvimento de algoritmos capazes de extrair conhecimento, identificar padrões e tomar decisões de forma automatizada a partir de dados históricos (Goldschmidt, 2005). No domínio da detecção de anomalias, as técnicas de aprendizado dividem-se fundamentalmente em duas abordagens: **supervisionadas** e **não supervisionadas** (Nunes *et al.*, 2021).

Nas abordagens supervisionadas (como *Support Vector Machines* – SVM, Árvores de Decisão e Regressão Logística), o modelo exige um conjunto de dados previamente rotulado (*labelled dataset*), no qual cada registro é formalmente classificado entre "regular" ou "anômalo" (*ground truth*). Contudo, como ressaltado por Nunes *et al.* (2021), a aplicação de modelos supervisionados sobre dados de finanças públicas é inviável na prática, uma vez que os microdados abertos dos portais de transparência não possuem rotulagem prévia de auditoria (Nunes *et al.*, 2021).

Diante da ausência de rótulos, a extração de atipicidades fundamenta-se no **Aprendizado de Máquina Não Supervisionado** (*Unsupervised Learning*). Essa abordagem assume que a imensa maioria dos registros da base representa transações normais e legítimas, enquanto as anomalias correspondem a observações raras que se distanciam estruturalmente do comportamento padrão (Goldschmidt, 2005; Nunes *et al.*, 2021). Para a execução deste projeto, destacam-se dois algoritmos não supervisionados consolidados na literatura:

5.4.1 *Isolation Forest* (ISO)

Proposto originalmente por Liu, Ting e Zhou (2008), o *Isolation Forest* (ISO) adota uma abordagem distinta dos algoritmos tradicionais baseados em distância ou densidade. Em vez de construir perfis de dados normais para posterior identificação de desvios, o ISO foca no **isolamento explícito das anomalias** (Liu; Ting; Zhou, 2008).

O algoritmo opera mediante a construção de um conjunto de árvores de decisão aleatórias (*iTrees*). Em cada nó da árvore, uma variável é selecionada aleatoriamente, seguida pela escolha de um ponto de corte arbitrário entre os valores mínimo e máximo dessa variável. Como as anomalias possuem atributos quantitativos atípicos ou frequências reduzidas, elas exigem poucas partições para serem completamente isoladas nas folhas mais rasas da árvore (Liu; Ting; Zhou, 2008).

Matematicamente, a pontuação de anomalia $s(x, n)$ de uma observação x em uma base de tamanho n é definida pela Equação 5.2:

$$s(x, n) = 2^{-\frac{E(h(x))}{c(n)}} \quad (5.2)$$

Em que $E(h(x))$ representa a média do comprimento do caminho de busca de x ao longo da floresta de árvores, e $c(n)$ é a extensão média de busca sem sucesso em uma árvore binária de busca construída com n nós. Quanto mais próximo de 1 for o escore s , maior é a probabilidade de a observação constituir uma anomalia isolada (Liu; Ting; Zhou, 2008). A grande vantagem do *Isolation Forest* em relação a outros algoritmos não supervisionados reside na sua baixa complexidade computacional e linearidade ($O(n \log n)$), tornando-o altamente eficiente para o processamento de bases populacionais volumosas como a do Portal da Transparência do Acre (Liu; Ting; Zhou, 2008; Pereira, 2025).

5.4.2 Local Outlier Factor (LOF)

Desenvolvido por Breunig *et al.* (2000), o *Local Outlier Factor* (LOF) é um algoritmo de detecção de anomalias baseado em densidade local que emprega a técnica dos k -vizinhos mais próximos (k -NN) (Breunig *et al.*, 2000). O pilar conceitual do LOF fundamenta-se na premissa de que a anomalia não deve ser definida apenas pela sua distância global ao centro da base, mas sim pelo seu grau de isolamento relativo em relação à densidade da sua vizinhança local (Breunig *et al.*, 2000; Vieira *et al.*, 2019).

Para cada ponto p da base, o algoritmo calcula a sua densidade de acessibilidade local (*local reachability density* – $lrd_k(p)$), comparando-a subsequentemente com a densidade de acessibilidade média dos seus k -vizinhos mais próximos. A razão entre essas densidades determina o fator de *outlier* local ($LOF_k(p)$), expresso pela Equação 5.3:

$$LOF_k(p) = \frac{\sum_{o \in N_k(p)} \frac{lrd_k(o)}{lrd_k(p)}}{|N_k(p)|} \quad (5.3)$$

Em que $N_k(p)$ representa o conjunto dos k -vizinhos mais próximos do ponto p . A interpretação do indicador LOF ocorre da seguinte forma (Breunig *et al.*, 2000):

- $LOF \approx 1$: Indica que o ponto possui densidade similar à de seus vizinhos, pertencendo a um agrupamento denso e homogêneo (padrão normal);
- $LOF < 1$: Representa observações localizadas no interior de agrupamentos muito densos;
- $LOF \gg 1$: Sinaliza que a densidade do ponto é significativamente menor do que a de seus vizinhos, caracterizando-o como um *outlier* local atípico.

A aplicação do LOF em dados da administração pública demonstra grande utilidade para identificar municípios ou órgãos cujos padrões de despesa destoam substancialmente de seus pares comparáveis (como demonstrado por Vieira, 2019 ao analisar repasses do SICONFI) (Vieira *et al.*, 2019). A integração combinada do *Isolation Forest* e do *Local Outlier Factor*

permite capturar tanto anomalias globais quanto desvios locais de densidade na base orçamentária do Estado do Acre (Breunig *et al.*, 2000; Liu; Ting; Zhou, 2008).

5.5 Mineração de Texto em Históricos Contábeis (NLP e DBSCAN)

Enquanto os campos numéricos e cadastrais das despesas públicas possibilitam análises quantitativas diretas, a real intenção e o detalhamento das contratações governamentais residem no campo descritivo de texto livre, denominado **histórico do empenho/pagamento**. O tratamento analítico dessa variável impõe desafios adicionais à Ciência de Dados devido à ausência de padronização, presença de abreviações informais, ruídos de digitação e variações sintáticas (Goldschmidt, 2005; Pereira, 2025).

Para converter esse conteúdo textual não estruturado em representações numéricas computáveis, utiliza-se a técnica de vetorização por Frequência do Termo–Inverso da Frequência nos Documentos (*Term Frequency–Inverse Document Frequency* – TF-IDF). A métrica TF-IDF pondera a relevância de uma palavra t em um histórico d pertencente a um conjunto de documentos D , penalizando termos excessivamente genéricos (como "referente", "pago", "aquisição") e valorizando termos discriminativos (como nomes de insumos, medicamentos ou serviços específicos) (Goldschmidt, 2005). Matematicamente, a ponderação é calculada pela Equação 5.4:

$$\text{TF-IDF}(t, d, D) = \text{TF}(t, d) \times \log \left(\frac{|D|}{|\{d \in D : t \in d\}|} \right) \quad (5.4)$$

Uma vez obtida a matriz esparsa de vetores TF-IDF, emprega-se o algoritmo de agrupamento baseado em densidade **DBSCAN** (*Density-Based Spatial Clustering of Applications with Noise*), proposto por Ester *et al.* (1996) (Ester *et al.*, 1996). Ao contrário de algoritmos de particionamento como o K-Means, o DBSCAN oferece três vantagens cruciais para a análise de despesas públicas (Ester *et al.*, 1996; Vieira *et al.*, 2019):

1. Não exige a definição prévia do número de agrupamentos (k);
2. Identifica agrupamentos de formatos geométricos arbitrários no espaço vetorial;
3. Isola autonomamente pontos de ruído (*noise*), isto é, históricos atípicos que não possuem densidade similar a nenhum grupo.

O DBSCAN é parametrizado pelo raio de vizinhança (ϵ) e pelo número mínimo de pontos (*MinPts*). Na auditoria contábil, a integração de TF-IDF com DBSCAN permite agrupar históricos de empenho com redações semanticamente equivalentes, viabilizando a identificação de variações atípicas de preços unitários em contratos similares, bem como a varredura automatizada de fracionamentos de licitação (*smurfing*) (Nunes *et al.*, 2021).

5.6 Trabalhos Relacionados

A consolidação da Ciência de Dados Forense aplicada ao setor público é evidenciada por um conjunto crescente de estudos que investigam a detecção de anomalias em bases orçamentárias brasileiras. O Quadro 1 sintetiza os principais trabalhos correlatos da literatura, destacando seus objetivos, métodos e a lacuna preenchida pelo presente TCC.

Tabela 1 – Quadro comparativo dos trabalhos relacionados na literatura nacional.

Autor / Documento	Domínio / Escopo	Metodologia Computacional	Diferencial / Foco Principal
Cavalcanti (2014) (Cavalcanti, 2014)	Cartão Corporativo (CPGF) – Governo Federal (2013)	Lei de Benford, Teste Z-Score, Qui-Quadrado e DAM	Validação jurídica e discricionariedade do uso de filtros estatísticos em auditorias do CPGF.
Cella (2018) (Cella, 2018)	Despesas Públicas Municipais – Estado de Goiás	Lei de Newcomb-Benford e Testes de Aderência Estatística	Avaliação de conformidade em contas municipais e identificação de distorções em dígitos iniciais.
Vieira (2019) (Vieira <i>et al.</i> , 2019)	Gastos Municipais – SICONFI / DATASUS / FIRJAN	Algoritmo LOF (<i>Local Outlier Factor</i>) e Framework KDD	Unificação de bases fiscais e indicadores sociais para redução de falsos positivos em prefeituras.
Asensi (2020) (Asensi; Santos; Costa, 2020)	Despesas Públicas Municipais	Mineração de Dados e Parametrização de Gastos	Parametrização de custos públicos e mapeamento de padrões atípicos de execução orçamentária.
Nunes <i>et al.</i> (2021) (Nunes <i>et al.</i> , 2021)	Cartão Corporativo (CPGF) – Exercícios 2018–2019	K-Means, Agrupamento Hierárquico e Redes Complexas	Detecção de anomalias sem rotulagem prévia em gastos federais via topologia de redes.
Pereira (2025) (Pereira, 2025)	Desembolsos Extraorçamentários – Estado de Goiás (2024)	Pipeline KDD, Lei de Benford, Z-Score e Qui-Quadrado em Python	Validação populacional (100% da base) do desvio no Dígito 1 como filtro inicial de triagem.
Estudo de Controle Interno Estadual (Interno, 2023)	Gestão e Controle Interno nos Estados Brasileiros	Levantamento de Práticas e Ciência de Dados	Mapeamento do nível de maturidade computacional e uso de dados abertos nas controladorias estaduais.
Estudo de CD em Dados Públicos (Silva; Pereira, 2023)	Bases Abertas de Despesas Governamentais	Mineração Exploratória e Estatística Descritiva	Aplicação de pipelines de limpeza e transformação sobre bases orçamentárias heterogêneas.
Análise de Anomalias Administrativas (Souza; Nascimento, 2024)	Dados de Execução Orçamentária e Financeira	Detecção Estatística de Atipicidades	Mapeamento de desvios em empenhos e liquidações na administração pública subnacional.

Fonte: Elaborado pelo autor com base na literatura correlata (2026).

A análise conjunta dos nove trabalhos relacionados sintetizados no Quadro 1 evidencia uma evolução metodológica clara: enquanto os estudos seminais (como Cavalcanti, 2014 e Cella, 2018) focaram prioritariamente na validação da estatística descritiva de Benford, pesquisas

subsequentes avançaram para a integração de algoritmos não supervisionados de densidade (Vieira, 2019) e topologia de redes (Nunes *et al.*, 2021), culminando na adoção de pipelines populacionais integrais em ambiente Python (Pereira, 2025) e no diagnóstico da maturidade do controle interno estadual.

A despeito desse panorama consolidado, constata-se uma lacuna no que tange à integração conjunta dessas técnicas (Benford, ISO, LOF e NLP) aplicada a bases populacionais subnacionais da Amazônia Sul-Occidental, cenário que fundamenta a oportunidade e o ineditismo do presente estudo de caso no Estado do Acre.

6 PROCEDIMENTOS METODOLÓGICOS

Neste capítulo, apresentam-se os procedimentos metodológicos, a caracterização da pesquisa, o ambiente computacional, as fontes de dados e o detalhamento do pipeline de Ciência de Dados desenvolvido para a execução do estudo de caso no Governo do Estado do Acre.

6.1 Estrutura do Pipeline Analítico

Para a fase de execução e implementação da proposta, a metodologia do trabalho integrará os seguintes pilares analíticos:

1. **Filtro Estatístico Paramétrico (Lei de Benford e Z-Score):** Utilizado como linha de base estatística para analisar a distribuição natural dos dígitos financeiros e identificar padronizações normativas, tais como a concentração de valores tabelados em diárias operacionais e auxílios institucionais (Cavalcanti, 2014; Nigrini, 2012);
2. **Algoritmos Não Supervisionados de Detecção de Anomalias:** Aplicação planejada dos algoritmos *Isolation Forest* (ISO) (Liu; Ting; Zhou, 2008) e *Local Outlier Factor* (LOF) (Breunig *et al.*, 2000) para o isolamento computacional de desvios e pontos discrepantes na distribuição dos gastos;
3. **Mineração de Texto e Agrupamento (NLP e DBSCAN):** Emprego de técnicas de Processamento de Linguagem Natural combinadas com algoritmos de agrupamento baseados em densidade para analisar os históricos contábeis e identificar contratos continuados em serviços essenciais;
4. **Representação Relacional Complementar:** Uso secundário de estruturas de redes para a representação visual da topologia de fornecedores e secretarias estaduais (Nunes *et al.*, 2021).

Dessa forma, esta pesquisa contribui para a literatura de Ciência de Dados Aplicada ao demonstrar como técnicas computacionais não supervisionadas podem servir como instrumentos de inteligência institucional, revelando dinâmicas organizacionais, gargalos normativos e padrões de alocação de recursos no Estado do Acre.

Para superar os gargalos da fiscalização analógica e converter grandes massas de dados orçamentários em inteligência fiscal, este trabalho propõe um pipeline computacional estruturado nas etapas do processo de Descoberta de Conhecimento em Bases de Dados (*Knowledge Discovery in Databases* – KDD). A Figura 2 ilustra a arquitetura geral do fluxo de processamento analítico desenvolvido.

Figura 2 – Fluxograma geral da esteira de Ciência de Dados Forense baseada no ciclo KDD.



Fonte: Elaborado pelo autor (2026).

A execução da esteira inicia-se pela compreensão das normas de execução orçamentária do setor público (Fase 1), seguida da coleta da totalidade dos microdados de despesa do Estado do Acre no período de 2020 a 2025 (Fase 2). Após a verificação exploratória de consistência (Fase 3) e o pré-processamento para limpeza de ruídos e extração de atributos numéricos (Fase 4), os dados passam pela filtragem estatística paramétrica da Lei de Benford e do Z-Score (Fase 5).

Na sequência, aplicam-se modelos não supervisionados de isolamento e densidade (*Isolation Forest* e LOF), técnicas de mineração de texto (TF-IDF e DBSCAN) e modelagem de redes complexas para identificar atipicidades quantitativas, semânticas e relacionais (Fase 6). Por fim, a Fase 7 dedica-se à conversão dos outputs algorítmicos em conhecimento estruturado, promovendo a interpretação contextual dos resultados para compreender os fenômenos sociais, econômicos e normativos subjacentes às anomalias detectadas.

6.2 Caracterização da Pesquisa

A condução deste trabalho fundamenta-se nas diretrizes da metodologia científica aplicada aos Sistemas de Informação e à Ciência de Dados, sendo classificada segundo quatro dimensões principais:

1. **Quanto à Natureza:** Classifica-se como uma **pesquisa aplicada**, pois visa produzir conhecimento direcionado à solução de um problema prático e concreto da gestão pública: a automação da triagem de despesas atípicas e a mitigação da "opacidade por excesso" nos dados abertos governamentais (Cavalcanti, 2014; Pereira, 2025);
2. **Quanto à Abordagem do Problema:** Trata-se de uma **pesquisa quantitativa e computacional**. A análise apoia-se na extração de métricas numéricas, testes estatísticos de aderência (Lei de Benford, Z-Score e Qui-Quadrado) e algoritmos de Aprendizado de Máquina Não Supervisionado para o mapeamento de anomalias sobre bases de dados estruturadas (Goldschmidt, 2005; Nunes *et al.*, 2021);
3. **Quanto aos Objetivos:** Caracteriza-se como uma **pesquisa exploratória e descritiva**. Exploratória ao investigar padrões não rotulados nos microdados orçamentários do Estado do Acre, e descritiva ao caracterizar detalhadamente a distribuição temporal, institucional e categórica das despesas e dos desvios identificados;
4. **Quanto aos Procedimentos Analíticos:** Configura-se como um **estudo de caso computacional**, focado na infraestrutura de dados abertos e na execução orçamentária do Poder Executivo do Estado do Acre no período de 2020 a 2025.

6.3 Fonte de Dados, Recorte Populacional e Atributos

A execução do estudo de caso fundamenta-se na extração e estruturação dos microdados financeiros abertos disponibilizados pelo Poder Executivo do Estado do Acre, por meio do seu Portal da Transparência.

6.3.1 Origem e Acesso aos Dados

Os dados foram obtidos via requisições diretas e rotinas de *web scraping*/ingestão de arquivos tabulares disponibilizados publicamente pela Controladoria-Geral do Estado do Acre (CGE-AC). Por se tratar de uma base de dados abertos governamentais submetida aos ditames da Lei de Acesso à Informação (Lei nº 12.527/2011), o acesso não exige credenciais restritas nem autorizações éticas específicas, garantindo a reprodutibilidade integral da coleta por órgãos de controle ou pela comunidade acadêmica.

6.3.2 Recorte Populacional e Temporal

Diferentemente de abordagens auditivas convencionais que operam por amostragem probabilística ou seletiva, este trabalho adota o princípio da **Análise Populacional Integral**. O recorte temporal estipulado abrange os exercícios orçamentários de **2020 a 2025**, compreendendo um volume superior a **429 mil registros financeiros** (fases de empenho, liquidação e pagamento). Essa delimitação de 6 anos permite capturar ciclos orçamentários completos, incluindo períodos

atípicos de gastos emergenciais (como o contexto da pandemia da COVID-19) e transições de gestão administrativa na esfera estadual.

6.3.3 Dicionário de Atributos e Seleção de Variáveis

Os microdados originais contêm múltiplas variáveis de natureza orçamentária, financeira e cadastral. Para a construção da esteira analítica e modelagem de anomalias, selecionou-se um conjunto prioritário de atributos, categorizados no Quadro 2:

Tabela 2 – Dicionário de atributos selecionados da base de despesas públicas do Estado do Acre.

Categoria	Nome da Variável	Tipo de Dado	Descrição e Aplicação no Pipeline
Financeira	valor_empenho / valor_pago	Numérico Contínuo (<i>float</i>)	Montante financeiro da transação. Base para extração do primeiro dígito (Benford), Z-Score e Isolation Forest.
Temporal	data_emissao / exercicio	Temporal (<i>datetime</i>) / Inteiro	Data e ano do registro contábil. Permite análise de evolução temporal, sazonalidade e frequência de empenhos.
Institucional	orgao_codigo / orgao_nome	Catégorico (<i>string</i>)	Identificação da Secretaria ou Órgão Estadual responsável pelo gasto. Utilizado em agrupamentos e no algoritmo LOF.
Cadastral	cpf_cnpj_credor / credor_nome	Catégorico (<i>string</i>)	Registro de identificação do fornecedor/favorecido. Base para grafos de rede, identificação de oligopólios e concentração.
Categorização	elemento_despesa / modalidade	Catégorico (<i>string</i>)	Classificação orçamentária da despesa e modalidade de licitação. Essencial para isolar falsos positivos de diárias e auxílios.
Textual	historico_empenho	Texto Livre (<i>string</i>)	Descrição textual da finalidade do gasto. Processado via NLP (TF-IDF) e agrupado por densidade via DBSCAN.

Fonte: Elaborado pelo autor com base nos dados do Portal da Transparência do Estado do Acre (2026).

6.4 A Esteira de Processamento de Dados (Pipeline KDD)

O processamento analítico dos microdados orçamentários do Estado do Acre segue rigorosamente as etapas do ciclo de Descoberta de Conhecimento em Bases de Dados (*Knowledge Discovery in Databases* – KDD) (Goldschmidt, 2005; Pereira, 2025). A esteira computacional foi

estruturada modularmente em ambiente Python, articulando tratamentos estatísticos e modelos de algoritmos não supervisionados.

6.4.1 Pré-processamento e Higienização de Dados (*Data Cleaning*)

A etapa inicial de pré-processamento foca na transformação dos arquivos brutos em uma estrutura tabular uniforme e livre de ruídos que possam comprometer a convergência dos algoritmos (Goldschmidt, 2005). Executam-se as seguintes rotinas computacionais:

1. **Tratamento de Valores Nulos e Inconsistentes:** Mapeamento e imputação/remoção de registros com variáveis essenciais ausentes (NaN), tais como valores zerados de empenho ou códigos de credor inconsistentes;
2. **Normalização de Identificadores Cadastrais:** Limpeza de caracteres especiais (pontos, traços e barras) nos campos de CPF e CNPJ dos favorecidos, aplicando preenchimento com zeros à esquerda (*zfill*) para garantir o padrão numérico de 11 e 14 dígitos;
3. **Tratamento de Estornos e Operações Negativas:** Conversão dos valores contábeis de anulação e estorno para o seu módulo absoluto ($|x|$), rotulando a natureza da transação para evitar distorções nas métricas agregadas de despesa acumulada;
4. **Padronização Temporal e Textual:** Conversão de datas para o formato padrão ISO 8601 (YYYY-MM-DD) e conversão de todo o texto dos históricos de empenho para caracteres minúsculos, removendo acentuação e pontuação desnecessária.

6.4.2 Engenharia de Atributos (*Feature Engineering*)

Nesta fase, constroem-se novas variáveis sintéticas a partir dos atributos brutos, com o objetivo de capturar comportamentos atípicos e fornecer insumos específicos para os modelos quantitativos e qualitativos (Pereira, 2025):

1. **Extração do Primeiro Dígito Significativo (*primeiro_digito*):** Isolamento do primeiro algarismo diferente de zero do valor numérico do empenho, variável indispensável para a aplicação da Lei de Benford;
2. **Frequência Recorrente por Favorecido (*freq_credor*):** Contagem automatizada do número de empenhos e liquidações emitidos para um mesmo CNPJ/CPF em janelas temporais de 30, 60 e 90 dias;
3. **Razão de Concentração do Favorecido (*razao_concentracao*):** Percentual do orçamento de uma determinada unidade gestora direcionado a um único credor no exercício financeiro;
4. **Variabilidade da Despesa (*desvio_relativo*):** Razão entre o valor de uma transação específica e a média histórica de pagamentos do mesmo elemento de despesa no órgão.

6.4.3 Módulo Estatístico Paramétrico: Lei de Benford e Z-Score

O primeiro filtro analítico atua sobre a variável `primeiro_digito` de 100% dos registros da base. O pipeline computacional executa dois testes formais de aderência (Nigrini, 2012; Cavalcanti, 2014):

1. **Teste Qui-Quadrado (χ^2):** Avalia a conformidade global da curva observada frente à distribuição teórica logarítmica de Benford. A rejeição da hipótese nula (H_0) ocorre para um nível de significância $\alpha = 0,05$ caso a estatística Q supere o valor crítico da distribuição;
2. **Teste Z-Score para Dígitos Individuais:** Identifica quais dígitos específicos de 1 a 9 apresentam frequências estatisticamente explodidas. O cálculo é regido pela Equação 6.1:

$$Z_d = \frac{|p_o - p_e| - \frac{1}{2n}}{\sqrt{\frac{p_e(1-p_e)}{n}}} \quad (6.1)$$

Em que p_o é a proporção observada do dígito d , p_e é a proporção esperada por Benford, n é o total de observações e $\frac{1}{2n}$ representa a correção de continuidade de Yates (Nigrini, 2012). Valores de $Z_d > 2,57$ sinalizam desvios atípicos ao nível de confiança de 99%.

6.4.4 Módulo de Aprendizado de Máquina Não Supervisionado: ISO e LOF

Para superar a dependência de análises unidimensionais e identificar anomalias multivariadas complexas em dados não rotulados, o pipeline aplica concorrentemente dois algoritmos de Aprendizado Não Supervisionado (Nunes *et al.*, 2021):

1. **Isolation Forest (ISO):** Treinado sobre o vetor de atributos quantitativos (valor, frequência, razão de concentração). Configura-se o parâmetro de contaminação (*contamination*) em um limiar conservador de 0,01 a 0,05, isolando 1% a 5% das observações mais distantes na estrutura de árvores binárias (Liu; Ting; Zhou, 2008);
2. **Local Outlier Factor (LOF):** Executado com hiperparâmetro de vizinhança $k = 20$, mensurando a densidade local de cada despesa em relação ao comportamento padrão do seu órgão de origem. Registros com escore $LOF > 1,5$ são formalmente rotulados como *outliers* locais de densidade (Breunig *et al.*, 2000).

6.4.5 Módulo de NLP e Agrupamento Semântico (TF-IDF + DBSCAN)

Como etapa de filtragem contextual e mitigação de falsos positivos causados por regras de negócio (como diárias e auxílios tabelados), o campo `historico_empenho` passa por um pipeline de Processamento de Linguagem Natural (Goldschmidt, 2005; Ester *et al.*, 1996):

1. **Vetorização TF-IDF:** Remoção de *stopwords* em português e construção da matriz esparsa de relevância de termos, limitando-se às 1.000 palavras mais discriminativas;

2. **Agrupamento com DBSCAN:** Aplicação do algoritmo DBSCAN sobre a matriz TF-IDF utilizando a métrica de distância do cosseno, com raio $\epsilon = 0,3$ e $MinPts = 5$. O modelo agrupa automaticamente descrições padronizadas por decretos administrativos e isola observações rotuladas como ruído (*label -1*), que indicam descrições atípicas ou suspeitas de fracionamento de licitação (*smurfing*) (Ester *et al.*, 1996; Vieira *et al.*, 2019).

6.5 Análise de Redes Complexas e Topologia de Grafos

Para além das abordagens estatísticas e algoritmos atômicos de amostragem, a estrutura de contratação pública do Estado do Acre apresenta uma dimensão relacional intrínseca: a conexão entre entes governamentais (órgãos/secretarias) e fornecedores privados (empresas/favorecidos). Para mapear essa dinâmica, o pipeline incorpora a **Teoria dos Grafos e a Análise de Redes Complexas** (Nunes *et al.*, 2021).

6.5.1 Modelagem de Rede Bipartida e Projeção

A relação orçamentária é modelada como um grafo não direcionado e ponderado $G = (V_{org}, V_{cred}, E)$, em que V_{org} representa o conjunto de nós dos órgãos públicos, V_{cred} denota o conjunto de nós dos credores/fornecedores e E representa as arestas de transação financeira, ponderadas pelo volume financeiro acumulado (W_{ij}) ou pelo número de empenhos celebrados:

1. **Mapeamento Bipartido:** Construção da matriz de adjacência A , conectando cada secretaria aos seus respectivos fornecedores contratados;
2. **Projeção Unimodal de Credores:** Projeção do grafo sobre o conjunto V_{cred} , conectando fornecedores distintos que compartilham contratos simultâneos em duas ou mais secretarias estaduais. Essa projeção evidencia a formação de consórcios informais, matrizes de fornecimento cruzado e dependência administrativa.

6.5.2 Métricas de Centralidade e Mapeamento de Oligopólios

Para quantificar a relevância topológica e identificar a concentração de mercado no setor público do Acre, calculam-se duas métricas de rede via biblioteca *networkx* (Nunes *et al.*, 2021):

1. **Centralidade de Grau (*Degree Centrality*):** Mede o número de órgãos estaduais distintos atendidos por uma mesma empresa, identificando fornecedores hiperconectados na estrutura administrativa;
2. **Centralidade de Intermediação (*Betweenness Centrality*):** Quantifica a frequência com que um credor atua como ponte de conexão no fluxo de empenhos entre diferentes setores governamentais.

Essa modelagem relacional permite isolar padrões de **oligopólio legal** decorrentes do uso intensivo de Atas de Registro de Preço ("caronas" interinstitucionais), separando empresas com forte penetração orçamentária legítima daquelas com indícios de direcionamento ou captura de mercado.

6.6 Ambiente Computacional e Ferramentas

A construção, validação e execução integral do pipeline analítico utilizam um ecossistema tecnológico baseado em linguagens, bibliotecas e plataformas de código aberto (*open-source*), garantindo custo zero de licenciamento e auditabilidade total (Pereira, 2025). A Tabela 3 detalha a infraestrutura computacional empregada:

Tabela 3 – Ambiente computacional e bibliotecas especializadas utilizadas na pesquisa.

Camada	Tecnologia / Biblioteca	Finalidade e Aplicação no Pipeline
Linguagem Base	Python 3.10+	Linguagem de programação científica para processamento e modelagem de dados.
Manipulação de Dados	pandas / numpy	Leitura de arquivos tabulares, limpeza, filtragem populacional e engenharia de atributos.
Estatística Forense	scipy.stats / statsmodels	Execução dos testes Qui-Quadrado (χ^2), cálculo de Z-Score e distribuições de Benford.
Machine Learning	scikit-learn	Implementação dos algoritmos <i>Isolation Forest</i> , <i>Local Outlier Factor</i> (LOF), DBSCAN e TF-IDF.
Análise de Redes	networkx / pyvis	Modelagem topológica de grafos bipartidos e visualização interativa de redes de fornecedores.
Visualização	matplotlib / seaborn	Geração de gráficos de distribuição, histogramas de dígitos e curvas de aderência.
Ambiente e Controle	Google Colab / GitHub	Nuvem computacional de execução analítica e versionamento de código-fonte.

Fonte: Elaborado pelo autor (2026).

6.7 Escore Integrado de Risco e Validação dos Resultados

Para evitar que os analistas do controle público precisem interpretar os outputs de múltiplos modelos isolados, o pipeline consolida os resultados em um **Escore Integrado de Risco Forense** (R_i), normalizado no intervalo $[0, 100]$ (Nunes *et al.*, 2021; Pereira, 2025).

6.7.1 Composição do Escore Integrado

O escore composto para cada transação i é calculado como a soma ponderada das sinalizações emitidas por cada filtro da esteira, conforme a Equação 6.2:

$$R_i = w_1 \cdot S_{\text{Benford}}(i) + w_2 \cdot S_{\text{ISO}}(i) + w_3 \cdot S_{\text{LOF}}(i) + w_4 \cdot S_{\text{DBSCAN}}(i) + w_5 \cdot S_{\text{Grafo}}(i) \quad (6.2)$$

Em que $S(i) \in \{0, 1\}$ indica a presença ou ausência de sinalização em cada módulo analítico, e w_k representa o peso atribuído a cada modelo com base na sua especificidade discriminativa. Registros que apresentam concordância multialgorítmica (sinalizados simultaneamente por Benford, ISO, LOF e DBSCAN) recebem pontuações de risco elevadas ($R_i > 75$), constituindo a amostra priorizada de triagem (*red flags*) (Nunes *et al.*, 2021).

6.7.2 Validação Qualitativa e Filtro de Falsos Positivos

A etapa final do procedimento metodológico consiste na **validação qualitativa do topo do escore de risco**. As despesas classificadas como de alto risco são submetidas a uma checagem contextual contra o arcabouço normativo governamental (decretos de diárias, tabelas de repasse e contratos públicos), verificando se a atipicidade identificada decorre de uma regra de negócio legítima (falso positivo) ou se constitui uma anomalia operacional que exige apuração pelos órgãos de controle (Cavalcanti, 2014; Nunes *et al.*, 2021).

7 CRONOGRAMA

O processo de escrita desta monografia seguirá o cronograma explicitado no Quadro 1.

Mês	Data	Dias	Atividade
Novembro	03-11-2025 até 17-11-2025	15	Escrita do Capítulo 1 - Introdução .
Novembro	18-11-2025 até 30-11-2025	13	Início da escrita do Capítulo 2 - Fundamentação Teórica .
Dezembro	01-12-2025 até 15-12-2025	15	Conclusão da escrita do Capítulo 2 - Fundamentação Teórica .
Dezembro	16-12-2025 até 23-12-2025	8	Etapa 1 e 2 (Planejamento e Identificação): Início da busca/seleção de estudos e redação do Capítulo 3 - Metodologia .
Janeiro	03-01-2026 até 12-01-2026	10	Conclusão da Etapa 1 e 2 e da redação do Capítulo 3 .
Janeiro	13-01-2026 até 31-01-2026	19	Etapa 3 e 4 (Extração e Visualização): Análise dos dados e início da redação do Capítulo 4 - Resultados .
Fevereiro	01-02-2026 até 06-02-2026	6	Conclusão da redação do Capítulo 4 - Resultados .
Fevereiro	07-02-2026 até 15-02-2026	9	Etapa 5 (Relatório): Redação do Capítulo 5 - Considerações Finais e entrega da versão completa para a orientadora.
Fevereiro	16-02-2026 até 28-02-2026	13	Período de revisão e aplicação dos ajustes finais.
Março	A definir em 03/2026	-	Preparação da apresentação e Defesa do Trabalho de Conclusão de Curso .

Fonte: Elaboração própria.

Quadro 1: Cronograma de execução da pesquisa.

8 ESBOÇO DOS CAPÍTULOS E SEÇÕES

A monografia final resultante deste projeto de pesquisa será estruturada em cinco capítulos principais, organizados de forma lógica e sequencial para apresentar o desenvolvimento da esteira de Ciência de Dados Forense e a análise dos microdados de despesas públicas do Estado do Acre. O esboço da estrutura do trabalho definitivo é apresentado a seguir:

1. INTRODUÇÃO

- **1.1. Problema da Pesquisa:** Apresentação do gargalo da fiscalização tradicional por amostragem e o fenômeno da opacidade por excesso nos portais de transparência.
- **1.2. Objetivos:**
 - **1.2.1. Geral:** Proposição e validação do pipeline computacional automatizado para auditoria contínua de despesas públicas.
 - **1.2.2. Específicos:** Etapas detalhadas da coleta populacional, pré-processamento, filtragem estatística, aprendizado não supervisionado, NLP e redes complexas.
- **1.3. Justificativa:** Relevância social, científica e tecnológica do estudo, destacando o ineditismo da análise populacional no Estado do Acre.
- **1.4. Metodologia Resumida:** Síntese da abordagem quantitativa aplicada e do ecossistema computacional em Python.
- **1.5. Organização do Trabalho:** Descrição da estrutura geral e encadeamento dos capítulos do documento.

2. FUNDAMENTAÇÃO TEÓRICA

- **2.1. Transparência Pública, Dados Abertos e Controle Social:** Evolução normativa (LRF, LAI) e o desafio da *Information Overload*.
- **2.2. O Processo KDD e a Análise Populacional:** O ciclo de descoberta de conhecimento em bases de dados e a transição da amostragem para a análise de 100% dos registros.
- **2.3. Filtros Estatísticos de Distribuição:** Fundamentos da Lei de Newcomb-Benford, Teste Qui-Quadrado (χ^2) e o Z-Score.
- **2.4. Aprendizado de Máquina Não Supervisionado:** Funcionamento dos algoritmos *Isolation Forest* (ISO) e *Local Outlier Factor* (LOF).
- **2.5. Mineração de Texto em Históricos Contábeis:** Vetorização TF-IDF e agrupamento denso via DBSCAN para filtragem contextual de falsos positivos.

- **2.6. Trabalhos Relacionados:** Mapeamento do estado da arte e lacunas na literatura nacional.

3. PROCEDIMENTOS METODOLÓGICOS

- **3.1. Caracterização da Pesquisa:** Classificação metodológica (pesquisa aplicada, quantitativa e estudo de caso).
- **3.2. Fonte de Dados, Recorte Populacional e Atributos:** Caracterização da base populacional do Estado do Acre (2020–2025, +429 mil registros) e dicionário de variáveis.
- **3.3. A Esteira de Processamento de Dados (Pipeline KDD):** Detalhamento das rotinas de limpeza, engenharia de atributos e parametrização dos modelos em Python.
- **3.4. Análise de Redes Complexas e Topologia de Grafos:** Modelagem bipartida e métricas de centralidade via NetworkX.
- **3.5. Ambiente Computacional e Ferramentas:** Mapeamento do ecossistema de software livre e bibliotecas especializadas.
- **3.6. Escore Integrado de Risco e Validação dos Resultados:** Formulação da matriz de concordância multialgorítmica e auditoria de falsos positivos.

4. RESULTADOS E DISCUSSÃO

- **4.1. Análise Exploratória e Diagnóstico Populacional:** Mapeamento quantitativo e temporal da execução orçamentária do Estado do Acre.
- **4.2. Triagem Estatística Descritiva:** Resultados da aderência à Lei de Benford, testes χ^2 e identificação de picos de Z-Score.
- **4.3. Detecção por Aprendizado Não Supervisionado:** Mapeamento de anomalias globais (ISO) e locais de densidade (LOF).
- **4.4. Agrupamento Semântico e Filtro de Falsos Positivos:** Resultados do TF-IDF/DBSCAN no isolamento de despesas normativas tabeladas (diárias e auxílios).
- **4.5. Estrutura de Redes e Oligopólios:** Projeção de grafos de fornecedores e diagnóstico do uso de Atas de Registro de Preço.
- **4.6. Desempenho do Escore Integrado de Risco:** Validação do ranking final de *red flags* para suporte à decisão auditiva.

5. CONSIDERAÇÕES FINAIS

- **5.1. Contribuições do Estudo:** Impactos práticos para os órgãos de controle e avanços científicos para a Ciência de Dados Cívica.
- **5.2. Limitações da Pesquisa:** Restrições da base de dados abertos (como ausência de metadados de quantidade e unidade) e desafios de infraestrutura.

- **5.3. Trabalhos Futuros:** Propostas de expansão do modelo (integração de chamadas de API do CNPJ/RFB e modelos de LLM para análise textual).

REFERÊNCIAS

- ASENSI, F.; SANTOS, A.; COSTA, B. Mineração de dados aplicada à detecção de padrões atípicos em despesas públicas municipais. **Revista de Gestão Pública e Transparência**, v. 8, n. 2, p. 88–113, 2020.
- BREUNIG, M. M. *et al.* Lof: Identifying density-based local outliers. **ACM SIGMOD Record**, v. 29, n. 2, p. 93–104, 2000.
- CAVALCANTI, G. H. d. V. **Aplicação da Lei de Newcomb-Benford na Identificação de Irregularidades: o exemplo dos gastos com cartões de pagamento do governo federal – CPGF**. Tese (Doutorado) — Controladoria-Geral da União (CGU), Brasília, 2014.
- CELLA, R. N. Aplicação da lei de newcomb-benford na análise de despesas municipais: Evidências de distorções em dígitos iniciais. **Revista Brasileira de Finanças Públicas**, v. 12, n. 1, p. 45–68, 2018.
- ESTER, M. *et al.* A density-based algorithm for discovering clusters in large spatial databases with noise. In: **Proceedings of the Second International Conference on Knowledge Discovery and Data Mining**. [S.l.]: AAAI Press, 1996.
- GOLDSCHMIDT, R. **Data Mining e Gestão Pública**. São Paulo: Editora XYZ, 2005.
- INTERNO, S. de Estado da Administração e C. **Diagnóstico de Maturidade em Controle Interno e Uso de Dados Abertos em Entes Estaduais Brasileiros**. [S.l.], 2023.
- LIU, F. T.; TING, K. M.; ZHOU, Z.-H. Isolation forest. In: **Proceedings of the 8th IEEE International Conference on Data Mining**. Pisa: IEEE, 2008.
- NIGRINI, M. J. **Benford's Law: Applications for Forensic Accounting, Auditing, and Fraud Detection**. New Jersey: Wiley, 2012.
- NUNES, B. O. *et al.* Anomaly detection in brazilian federal government purchase cards through unsupervised learning techniques. **IEEE Access**, v. 9, p. 1–15, 2021.
- PEREIRA, J. P. T. **Ciência de Dados Aplicada na Detecção de Fraude em Demonstrações Financeiras**. Goiânia: [s.n.], 2025. Trabalho de Conclusão de Curso – PUC Goiás.
- SILVA, A.; PEREIRA, J. **Pipeline de Ciência de Dados em Bases Abertas de Despesas Governamentais**. 2023. Relatório Técnico Interno.
- SOUZA, M.; NASCIMENTO, P. **Análise de Anomalias Administrativas em Despesas de Execução Orçamentária**. 2024. Nota Técnica de Monitoramento Governamental.
- VIEIRA, R. *et al.* Detecção de anomalias em gastos públicos por meio de técnicas de aprendizado não supervisionado. **Revista de Informática Aplicada**, v. 15, n. 2, p. 120–138, 2019.