



Universidade Federal do Acre

Guilherme de Jesus Carvalho

**Ciência de Dados Aplicada Na Detecção de Anomalias em
Portais de Transparências: Um Estudo de Caso do Governo do
Estado do Acre**

Rio Branco
2026

Guilherme de Jesus Carvalho

**Ciência de Dados Aplicada Na Detecção de Anomalias em
Portais de Transparências: Um Estudo de Caso do Governo do
Estado do Acre**

Universidade Federal do Acre

Orientador: Prof. Dra. Laura Costa Sarkis
Coorientador: Prof. Dra. Lorena Caceres Tomaya

Rio Branco
2026

LISTA DE ILUSTRAÇÕES

LISTA DE QUADROS

1	Cronograma de execução da pesquisa.	18
*		

SUMÁRIO

1	APRESENTAÇÃO	5
2	PROBLEMA DA PESQUISA	7
3	OBJETIVOS DA PESQUISA	9
3.1	Objetivo Geral	9
3.2	Objetivos Específicos	9
4	JUSTIFICATIVA DA PESQUISA	11
4.1	Relevância Social e Prática	11
4.2	Relevância Científica e Acadêmica	11
4.3	Relevância Técnica e Tecnológica	12
4.4	Viabilidade da Pesquisa	12
5	FUNDAMENTAÇÃO TEÓRICA	14
5.1	Assunto 1	14
5.2	Assunto 2	14
5.3	Assunto 3	14
5.4	Trabalhos Relacionados	14
6	PROCEDIMENTOS METODOLÓGICOS	15
7	RESULTADOS	16
7.1	PIPELINE KDD E COBERTURA POPULACIONAL	16
7.2	FILTRO ESTATÍSTICO DE BENFORD E Z-SCORE	16
7.2.1	Diagnóstico de Falsos Positivos	16
7.3	REDES DE GRAFOS E OLIGOPÓLIOS ESTRUTURAIS	16
7.4	ALGORITMO DE SMURFING E O ESTUDO DE CASO 4HEALTH	16
7.5	DIAGNÓSTICO FORENSE	17
8	CRONOGRAMA	18
	Referências	19

1 APRESENTAÇÃO

A crescente digitalização da administração pública e a consolidação dos portais de transparência governamentais têm disponibilizado volumes massivos de microdados sobre a execução orçamentária e financeira do setor público no Brasil. Contudo, a simples publicação bruta desses dados em tabelas e relatórios nem sempre se traduz em conhecimento acessível para a sociedade ou em insights estratégicos para a Gestão Pública, dada a elevada complexidade e assimetria das transações financeiras (Cavalcanti, 2014; Pereira, 2025). Neste cenário, a Ciência de Dados e o processo de Descoberta de Conhecimento em Bases de Dados (*Knowledge Discovery in Databases* – KDD) emergem como campos interdisciplinares fundamentais para transformar grandes volumes de dados não estruturados em conhecimento útil e interpretável (Goldschmidt, 2005). Em vez de recorrer a técnicas tradicionais de amostragem restrita, a aplicação de algoritmos computacionais permite o processamento populacional integral (100% dos registros), garantindo uma análise holística da dinâmica dos gastos públicos (Pereira, 2025). Como a base de dados do Portal da Transparência é composta por dados abertos não rotulados (*unlabelled data*) — isto é, sem a indicação prévia do que constitui um lançamento regular ou uma anomalia —, a aplicação de modelos de aprendizado de máquina supervisionado (como SVM e algoritmos de classificação) torna-se inviável na prática. Por essa razão, este projeto de pesquisa adota rigorosamente a abordagem de **Aprendizado de Máquina Não Supervisionado** (*Unsupervised Machine Learning*) e estatística descritiva, permitindo a descoberta de padrões ocultos e agrupamentos sem a necessidade de um gabarito prévio (Nunes *et al.*, 2021). O presente projeto de Trabalho de Conclusão de Curso (TCC) propõe o desenvolvimento de um pipeline computacional aplicado sobre a base populacional de despesas do Portal da Transparência do Estado do Acre, englobando mais de 429 mil registros financeiros referentes ao período de 2020 a 2025. O objetivo central deste estudo não reside na acusação criminal ou auditoria investigativa de ilícitos, mas sim no uso da Ciência de Dados para mapear, visualizar e compreender os fenômenos socioadministrativos reais que moldam a gestão pública acreana. Para a fase de execução e implementação da proposta, a metodologia do trabalho integrará os seguintes pilares analíticos:

1. **Filtro Estatístico Paramétrico (Lei de Benford e Z-Score):** Utilizado como linha de base estatística para analisar a distribuição natural dos dígitos financeiros e identificar padronizações normativas, tais como a concentração de valores tabelados em diárias operacionais e auxílios institucionais (Cavalcanti, 2014; Nigrini, 2012);
2. **Algoritmos Não Supervisionados de Detecção de Anomalias:** Aplicação planejada dos algoritmos *Isolation Forest* (ISO) (Liu; Ting; Zhou, 2008) e *Local Outlier Factor* (LOF) (Breunig *et al.*, 2000) para o isolamento computacional de desvios e pontos discrepantes na distribuição dos gastos;

3. **Mineração de Texto e Agrupamento (NLP e DBSCAN):** Emprego de técnicas de Processamento de Linguagem Natural combinadas com algoritmos de agrupamento baseados em densidade para analisar os históricos contábeis e identificar contratos continuados em serviços essenciais;
4. **Representação Relacional Complementar:** Uso secundário de estruturas de redes para a representação visual da topologia de fornecedores e secretarias estaduais (Nunes *et al.*, 2021).

Dessa forma, esta pesquisa contribui para a literatura de Ciência de Dados Aplicada ao demonstrar como técnicas computacionais não supervisionadas podem servir como instrumentos de inteligência institucional, revelando dinâmicas organizacionais, gargalos normativos e padrões de alocação de recursos no Estado do Acre.

2 PROBLEMA DA PESQUISA

A garantia da transparência pública e o fortalecimento do controle social no Brasil foram impulsionados pela promulgação da Lei de Acesso à Informação (Lei nº 12.527/2011) e pela Lei de Responsabilidade Fiscal (Lei Complementar nº 101/2000). Esses marcos normativos obrigaram os entes federativos a disponibilizarem, em meios eletrônicos, informações detalhadas sobre a execução orçamentária em tempo real. No entanto, os portais de transparência governamentais abrigam bases dinâmicas com milhões de lançamentos contínuos acumulados ao longo dos anos. Essa escala massiva frequentemente resulta no fenômeno da "opacidade por excesso" (*information overload*), no qual a simples publicação bruta de dados não estruturados cria barreiras para a interpretação pública (Cavalcanti, 2014; Pereira, 2025). No âmbito do controle institucional, órgãos formais como a Controladoria-Geral da União (CGU) e os Tribunais de Contas Estaduais (TCE) dispõem de auditores especializados e sistemas proprietários de inteligência para fiscalização interna. Contudo, essas ferramentas restritas não estão acessíveis à sociedade civil, a jornalistas de dados e à comunidade acadêmica, que dependem exclusivamente dos microdados abertos publicados nos portais. Para este público, a análise manual de bases massivas mostra-se inviável, demandando metodologias abertas de Ciência de Dados para a automação da triagem e extração de conhecimento (Nunes *et al.*, 2021). No contexto da pesquisa "**Ciência de Dados Aplicada na Detecção de Anomalias em Portais de Transparência: Um Estudo de Caso do Governo do Estado do Acre**", a análise foca no recorte populacional de mais de 429 mil registros financeiros referentes ao período de 2020 a 2025. A partir desse ecossistema de dados abertos, emergem desafios centrais de Ciência de Dados e Aprendizado de Máquina (*Machine Learning*):

1. **Ausência de Rotulagem (*Unlabelled Data*):** Os dados abertos dos portais de transparência não possuem rotulação prévia (*ground truth*) que identifique empenhos normais ou anômalos. A inexistência de um gabarito inviabiliza o uso direto de modelos supervisionados (como SVM e Árvores de Decisão), exigindo o emprego de algoritmos de **Aprendizado Não Supervisionado** (*Isolation Forest – ISO, Local Outlier Factor – LOF e DBSCAN*) aliados a testes de distribuição estatística (Lei de Benford e Z-Score) (Nunes *et al.*, 2021; Goldschmidt, 2005);
2. **Complexidade Normativa e Falsos Positivos:** O uso isolado de testes estatísticos pode gerar falsos positivos ao identificar concentrações de pagamentos perfeitamente legítimos, mas tabelados por decretos (como diárias e auxílios operacionais). A superação desse gargalo exige a integração de técnicas de Processamento de Linguagem Natural (NLP) sobre os históricos contábeis para contextualizar o texto livre das despesas (Cavalcanti, 2014);

3. **Ineditismo e Lacuna de Pesquisa na Região Acreana:** A literatura nacional sobre Ciência de Dados e transparência pública concentra suas aplicações predominantemente na esfera federal ou em estados do Sul e Sudeste (Cavalcanti, 2014; Nunes *et al.*, 2021). O levantamento exploratório confirma a escassez de estudos computacionais dedicados à infraestrutura e aos microdados do Portal da Transparência do Estado do Acre, evidenciando uma lacuna científica regional que justifica a realização deste estudo de caso.

Diante dessa problemática, formula-se a seguinte **Pergunta de Pesquisa** que orienta este trabalho:

Em que medida a aplicação de um pipeline de Ciência de Dados baseado em Aprendizado Não Supervisionado (Isolation Forest, Local Outlier Factor e DBSCAN), testes estatísticos descritivos (Lei de Benford e Z-Score) e Processamento de Linguagem Natural permite identificar, filtrar e interpretar anomalias e padrões socioadministrativos nos microdados abertos do Portal da Transparência do Estado do Acre (2020–2025), sem a necessidade de dados previamente rotulados?

3 OBJETIVOS DA PESQUISA

Com o intuito de responder à pergunta de pesquisa formulada e viabilizar a análise computacional dos microdados abertos do setor público, este capítulo delimita o objetivo geral e os objetivos específicos que norteiam o desenvolvimento deste trabalho.

3.1 Objetivo Geral

Desenvolver e avaliar uma metodologia baseada em técnicas de Ciência de Dados e Aprendizado de Máquina para detectar padrões anômalos nas despesas públicas registradas no Portal da Transparência e relacionadas ao Estado do Acre, identificando transações ou grupos de transações que apresentem comportamento atípico em relação aos padrões históricos de execução da despesa.

3.2 Objetivos Específicos

Para o alcance do objetivo geral, estabelecem-se os seguintes objetivos específicos:

1. **Obtenção e Pré-processamento de Dados:** Obter, organizar e realizar o pré-processamento dos dados de despesas públicas relacionadas ao Estado do Acre disponíveis no Portal da Transparência, considerando as variáveis financeiras, temporais, institucionais e cadastrais disponíveis;
2. **Caracterização Estatística Exploratória:** Caracterizar estatisticamente o comportamento das despesas, avaliando sua distribuição, concentração, variabilidade e evolução temporal segundo órgão, unidade gestora, favorecido, natureza da despesa e demais categorias disponíveis;
3. **Engenharia de Atributos (*Feature Engineering*):** Construir atributos capazes de representar comportamentos potencialmente atípicos das despesas, considerando, além do valor da transação, características como frequência, recorrência, concentração por favorecido e variação temporal;
4. **Modelagem Não Supervisionada:** Aplicar técnicas de Aprendizado de Máquina Não Supervisionado para identificar observações ou padrões anômalos nas despesas analisadas;
5. **Comparação e Concordância Algorítmica:** Comparar o desempenho e a concordância entre diferentes métodos de detecção de anomalias, identificando despesas classificadas como atípicas por uma ou mais técnicas;

6. **Investigação Socioadministrativa dos Padrões:** Investigar a distribuição das anomalias identificadas segundo órgãos, favorecidos, categorias de despesa e períodos de execução, buscando reconhecer padrões recorrentes;
7. **Construção de Escore de Priorização:** Desenvolver um escore ou classificação de prioridade das observações detectadas, de forma a auxiliar na seleção das despesas que mereçam análise mais detalhada;
8. **Avaliação de Impacto e Aplicabilidade:** Avaliar a aplicabilidade das técnicas de Ciência de Dados como instrumento complementar de transparência e controle dos gastos públicos.

4 JUSTIFICATIVA DA PESQUISA

A relevância deste Trabalho de Conclusão de Curso fundamenta-se na interseção entre a Ciência de Dados, a Ciência da Informação e a Gestão Pública, desdobrando-se nas dimensões social, científica, técnica e prática.

4.1 Relevância Social e Prática

A consolidação do princípio constitucional da publicidade e os avanços promovidos pela Lei de Acesso à Informação (Lei nº 12.527/2011) garantiram o direito fundamental de acesso aos dados orçamentários do setor público brasileiro. Contudo, a simples publicação de relatórios contábeis extensos e dados brutos nos portais de transparência não assegura, por si só, a efetividade da transparência pública. Na prática, a sociedade civil, jornalistas de dados e a comunidade acadêmica enfrentam o fenômeno da "opacidade por excesso" (*information overload*), no qual o volume massivo e desestruturado de informações impede a compreensão direta sobre como os recursos públicos estão sendo alocados (Cavalcanti, 2014; Pereira, 2025).

Nesse contexto, a aplicação de técnicas de Ciência de Dados atua como um instrumento de democratização da informação e fortalecimento do controle social. Ao transformar microdados financeiros brutos em representações analíticas compreensíveis e padrões interpretáveis, a pesquisa contribui para reduzir a assimetria de informação entre a administração governamental e o cidadão. Além disso, no âmbito prático da gestão pública, o desenvolvimento de mecanismos abertos de triagem automatizada permite identificar gargalos normativos e padrões atípicos de execução orçamentária, fornecendo subsídios para o aprimoramento da eficiência administrativa e do planejamento de políticas públicas no Estado do Acre.

4.2 Relevância Científica e Acadêmica

Apesar da expansão de pesquisas dedicadas ao uso de técnicas computacionais e estatísticas na fiscalização de gastos públicos no Brasil, observa-se que a literatura científica nacional concentra suas aplicações predominantemente em dados federais — como o Cartão de Pagamento do Governo Federal (CPGF) e o SICONFI — ou em grandes metrópoles das regiões Sul e Sudeste (Cavalcanti, 2014; Nunes *et al.*, 2021). Em contrapartida, o ecossistema de dados abertos dos entes subnacionais da Região Norte, em especial do Estado do Acre, permanece subexplorado pela pesquisa em Ciência de Dados e Sistemas de Informação.

O ineditismo regional desta pesquisa reside justamente na aplicação e validação de um pipeline computacional não supervisionado sobre a base populacional de despesas do Poder Executivo do Estado do Acre. Do ponto de vista científico, o estudo preenche uma lacuna relevante

na literatura ao investigar como modelos de detecção de anomalias e testes estatísticos de distribuição comportam-se diante das especificidades orçamentárias, normativas e fornecedoras de uma unidade federativa da Amazônia Sul-Occidental. Assim, o trabalho amplia a validade externa das metodologias de Ciência de Dados aplicadas à transparência pública, fornecendo um arcabouço metodológico reprodutível e replicável para outros estados com dinâmicas administrativas semelhantes (Pereira, 2025).

4.3 Relevância Técnica e Tecnológica

Do ponto de vista tecnológico e computacional, a justificativa deste trabalho assenta-se na superação dos limites impostos pelas abordagens analógicas e amostrais tradicionais de fiscalização. A análise populacional integral — que abrange 100% dos mais de 429 mil registros do recorte temporal estipulado — garante que nenhum evento atípico seja omitido por viés de seleção ou corte arbitrário de dados, aumentando a confiabilidade da triagem (Pereira, 2025).

Ademais, a arquitetura metodológica proposta responde a um desafio técnico central na mineração de dados abertos governamentais: a ausência de rótulos prévios (*unlabelled data*). Ao integrar modelos de Aprendizado de Máquina Não Supervisionado (*Isolation Forest*, *Local Outlier Factor* e *DBSCAN*) a testes estatísticos de distribuição (Lei de Benford e Z-Score) e técnicas de Processamento de Linguagem Natural (NLP), a pesquisa estabelece um pipeline computacional capaz de identificar anomalias estruturais e isolar falsos positivos decorrentes de regras normativas da administração pública (Cavalcanti, 2014; Nunes *et al.*, 2021; Goldschmidt, 2005). Trata-se de uma solução tecnológica reprodutível e orientada à automação do processo de triagem contábil.

4.4 Viabilidade da Pesquisa

A viabilidade técnica, operacional e temporal deste projeto de pesquisa é plenamente assegurada pela conjugação de três fatores fundamentais: a disponibilidade de dados públicos abertos, o uso de ecossistemas computacionais de código aberto (*open-source*) e o avanço prévio do pipeline de dados.

Em primeiro lugar, a garantia de acesso aos microdados é respaldada pela legislação nacional de transparência (Lei nº 12.527/2011), uma vez que a totalidade das informações necessárias provém do Portal da Transparência do Estado do Acre, um ecossistema de dados abertos e de livre acesso que não impõe barreiras legais ou restrições de sigilo à extração de dados orçamentários.

Em segundo lugar, a exequibilidade computacional do trabalho apoia-se no uso da linguagem de programação Python e do seu ecossistema científico especializado (*pandas*, *numpy*, *scikit-learn*, *seaborn* e *networkx*). A opção por bibliotecas abertas e consolidadas elimina a dependência de licenças de software proprietário de alto custo e assegura a transparência e a reprodutibilidade integral do pipeline analítico (Pereira, 2025).

Por fim, a viabilidade cronológica é corroborada pela fase adiantada de preparação da base de dados. O processo de extração, limpeza e padronização do recorte populacional do Estado do Acre (2020–2025) — englobando mais de 429 mil registros financeiros — já se encontra concluído e validado em ambiente computacional. Esse amadurecimento técnico prévio mitiga riscos operacionais e assegura o cumprimento rigoroso do cronograma acadêmico estipulado para a execução do TCC.

5 FUNDAMENTAÇÃO TEÓRICA

Nesta seção serão abordados alguns conceitos fundamentais para a realização deste trabalho, tais como:

5.1 Assunto 1

5.2 Assunto 2

5.3 Assunto 3

5.4 Trabalhos Relacionados

6 PROCEDIMENTOS METODOLÓGICOS

7 RESULTADOS

7.1 PIPELINE KDD E COBERTURA POPULACIONAL

- Processamento automatizado de 100% da base de dados do Portal da Transparência do Acre via scripts em Python.
- Análise abrangente contemplando mais de 429 mil registros de despesas públicas no período entre 2020 e 2025.

7.2 FILTRO ESTATÍSTICO DE BENFORD E Z-SCORE

7.2.1 Diagnóstico de Falsos Positivos

- Detecção de anomalias estatísticas expressivas localizadas nos Dígitos 4 ($Z = +9,97$) e 7 ($Z = +25,66$).
- A análise qualitativa de texto (NLP) revelou que esses picos não representavam fraudes mascaradas.
- Constatou-se a presença de "falsos positivos" causados diretamente por padronizações normativas, especificamente os valores tabelados de diárias civis e militares oriundos do Fundo Penitenciário.

7.3 REDES DE GRAFOS E OLIGOPÓLIOS ESTRUTURAIS

- Mapeamento de matrizes de co-ocorrência utilizando as bibliotecas *NetworkX* e *PyVis*.
- Evidenciou-se uma altíssima centralização de mercado na administração estadual.
- Identificação de um núcleo reduzido de empresas atuando simultaneamente em até 28 secretarias de estado, viabilizado pelo uso intensivo de Atas de Registro de Preço (prática de "Caronas").

7.4 ALGORITMO DE SMURFING E O ESTUDO DE CASO 4HEALTH

- O algoritmo de varredura projetado para detectar dispensa de licitação identificou um total de R\$ 12,07 milhões distribuídos em 9 repasses.

- Destinatária dos recursos: 4Health Serviços Médicos Ltda, através do Fundo Estadual de Saúde (FUNDES/SESACRE).
- A inspeção dos históricos contábeis, baseada nos processos SEI e nos Contratos 677/2023 e 862/2024, revelou a prestação continuada de serviços de anestesiologia via dispensa de licitação ao longo de 3 anos consecutivos (2023 a 2025).

7.5 DIAGNÓSTICO FORENSE

- O modelo analítico demonstrou capacidade robusta de extrapolar a detecção do fracionamento comum de pequeno valor (*smurfing*).
- Exposição de um cenário caracterizado por "emergência fabricada" ou inércia administrativa.
- O contexto anômalo detectado é respaldado pela escassez crônica de médicos anesthesiologistas na região e pelos sucessivos decretos de emergência climática emitidos no Acre.

8 CRONOGRAMA

O processo de escrita desta monografia seguirá o cronograma explicitado no Quadro 1.

Mês	Data	Dias	Atividade
Novembro	03-11-2025 até 17-11-2025	15	Escrita do Capítulo 1 - Introdução .
Novembro	18-11-2025 até 30-11-2025	13	Início da escrita do Capítulo 2 - Fundamentação Teórica .
Dezembro	01-12-2025 até 15-12-2025	15	Conclusão da escrita do Capítulo 2 - Fundamentação Teórica .
Dezembro	16-12-2025 até 23-12-2025	8	Etapa 1 e 2 (Planejamento e Identificação): Início da busca/seleção de estudos e redação do Capítulo 3 - Metodologia .
Janeiro	03-01-2026 até 12-01-2026	10	Conclusão da Etapa 1 e 2 e da redação do Capítulo 3 .
Janeiro	13-01-2026 até 31-01-2026	19	Etapa 3 e 4 (Extração e Visualização): Análise dos dados e início da redação do Capítulo 4 - Resultados .
Fevereiro	01-02-2026 até 06-02-2026	6	Conclusão da redação do Capítulo 4 - Resultados .
Fevereiro	07-02-2026 até 15-02-2026	9	Etapa 5 (Relatório): Redação do Capítulo 5 - Considerações Finais e entrega da versão completa para a orientadora.
Fevereiro	16-02-2026 até 28-02-2026	13	Período de revisão e aplicação dos ajustes finais.
Março	A definir em 03/2026	-	Preparação da apresentação e Defesa do Trabalho de Conclusão de Curso .

Fonte: Elaboração própria.

Quadro 1: Cronograma de execução da pesquisa.

REFERÊNCIAS

- BREUNIG, M. M. *et al.* Lof: Identifying density-based local outliers. **ACM SIGMOD Record**, v. 29, n. 2, p. 93–104, 2000.
- CAVALCANTI, G. H. d. V. **Aplicação da Lei de Newcomb-Benford na Identificação de Irregularidades: o exemplo dos gastos com cartões de pagamento do governo federal – CPGF**. Tese (Doutorado) — Controladoria-Geral da União (CGU), Brasília, 2014.
- GOLDSCHMIDT, R. **Data Mining e Gestão Pública**. São Paulo: Editora XYZ, 2005.
- LIU, F. T.; TING, K. M.; ZHOU, Z.-H. Isolation forest. In: **Proceedings of the 8th IEEE International Conference on Data Mining**. Pisa: IEEE, 2008.
- NIGRINI, M. J. **Benford’s Law: Applications for Forensic Accounting, Auditing, and Fraud Detection**. New Jersey: Wiley, 2012.
- NUNES, B. O. *et al.* Anomaly detection in brazilian federal government purchase cards through unsupervised learning techniques. **IEEE Access**, v. 9, p. 1–15, 2021.
- PEREIRA, J. P. T. **Ciência de Dados Aplicada na Detecção de Fraude em Demonstrações Financeiras**. Goiânia: [s.n.], 2025. Trabalho de Conclusão de Curso – PUC Goiás.