



Universidade Federal do Acre

Guilherme de Jesus Carvalho

**Ciência de Dados Aplicada Na Detecção de Anomalias em
Portais de Transparências: Um Estudo de Caso do Governo do
Estado do Acre**

Rio Branco
2026

Guilherme de Jesus Carvalho

**Ciência de Dados Aplicada Na Detecção de Anomalias em
Portais de Transparências: Um Estudo de Caso do Governo do
Estado do Acre**

Universidade Federal do Acre

Orientador: Prof. Dra. Laura Costa Sarkis
Coorientador: Prof. Dra. Lorena Caceres Tomaya

Rio Branco
2026

LISTA DE ILUSTRAÇÕES

LISTA DE QUADROS

1	Cronograma de execução da pesquisa.	14
*		

SUMÁRIO

1	APRESENTAÇÃO	5
2	PROBLEMA DA PESQUISA	7
3	OBJETIVOS DA PESQUISA	8
3.1	OBJETIVO GERAL	8
3.2	OBJETIVOS ESPECÍFICOS	8
4	JUSTIFICATIVA DA PESQUISA	9
5	FUNDAMENTAÇÃO TEÓRICA	10
5.1	Assunto 1	10
5.2	Assunto 2	10
5.3	Assunto 3	10
5.4	Trabalhos Relacionados	10
6	PROCEDIMENTOS METODOLÓGICOS	11
7	RESULTADOS	12
7.1	PIPELINE KDD E COBERTURA POPULACIONAL	12
7.2	FILTRO ESTATÍSTICO DE BENFORD E Z-SCORE	12
7.2.1	Diagnóstico de Falsos Positivos	12
7.3	REDES DE GRAFOS E OLIGOPÓLIOS ESTRUTURAIS	12
7.4	ALGORITMO DE SMURFING E O ESTUDO DE CASO 4HEALTH	12
7.5	DIAGNÓSTICO FORENSE	13
8	CRONOGRAMA	14
	Referências	15

1 APRESENTAÇÃO

A crescente digitalização da administração pública e a consolidação dos portais de transparência governamentais têm disponibilizado volumes massivos de microdados sobre a execução orçamentária e financeira do setor público no Brasil. Contudo, a simples publicação bruta desses dados em tabelas e relatórios nem sempre se traduz em conhecimento acessível para a sociedade ou em insights estratégicos para a Gestão Pública, dada a elevada complexidade e assimetria das transações financeiras (Cavalcanti, 2014; Pereira, 2025). Neste cenário, a Ciência de Dados e o processo de Descoberta de Conhecimento em Bases de Dados (*Knowledge Discovery in Databases* – KDD) emergem como campos interdisciplinares fundamentais para transformar grandes volumes de dados não estruturados em conhecimento útil e interpretável (Goldschmidt, 2005). Em vez de recorrer a técnicas tradicionais de amostragem restrita, a aplicação de algoritmos computacionais permite o processamento populacional integral (100% dos registros), garantindo uma análise holística da dinâmica dos gastos públicos (Pereira, 2025). Como a base de dados do Portal da Transparência é composta por dados abertos não rotulados (*unlabelled data*) — isto é, sem a indicação prévia do que constitui um lançamento regular ou uma anomalia —, a aplicação de modelos de aprendizado de máquina supervisionado (como SVM e algoritmos de classificação) torna-se inviável na prática. Por essa razão, este projeto de pesquisa adota rigorosamente a abordagem de **Aprendizado de Máquina Não Supervisionado** (*Unsupervised Machine Learning*) e estatística descritiva, permitindo a descoberta de padrões ocultos e agrupamentos sem a necessidade de um gabarito prévio (Nunes *et al.*, 2021). O presente projeto de Trabalho de Conclusão de Curso (TCC) propõe o desenvolvimento de um pipeline computacional aplicado sobre a base populacional de despesas do Portal da Transparência do Estado do Acre, englobando mais de 429 mil registros financeiros referentes ao período de 2020 a 2025. O objetivo central deste estudo não reside na acusação criminal ou auditoria investigativa de ilícitos, mas sim no uso da Ciência de Dados para mapear, visualizar e compreender os fenômenos socioadministrativos reais que moldam a gestão pública acreana. Para a fase de execução e implementação da proposta, a metodologia do trabalho integrará os seguintes pilares analíticos:

1. **Filtro Estatístico Paramétrico (Lei de Benford e Z-Score):** Utilizado como linha de base estatística para analisar a distribuição natural dos dígitos financeiros e identificar padronizações normativas, tais como a concentração de valores tabelados em diárias operacionais e auxílios institucionais (Cavalcanti, 2014; Nigrini, 2012);
2. **Algoritmos Não Supervisionados de Detecção de Anomalias:** Aplicação planejada dos algoritmos *Isolation Forest* (ISO) (Liu; Ting; Zhou, 2008) e *Local Outlier Factor* (LOF) (Breunig *et al.*, 2000) para o isolamento computacional de desvios e pontos discrepantes na distribuição dos gastos;

3. **Mineração de Texto e Agrupamento (NLP e DBSCAN):** Emprego de técnicas de Processamento de Linguagem Natural combinadas com algoritmos de agrupamento baseados em densidade para analisar os históricos contábeis e identificar contratos continuados em serviços essenciais;
4. **Representação Relacional Complementar:** Uso secundário de estruturas de redes para a representação visual da topologia de fornecedores e secretarias estaduais (Nunes *et al.*, 2021).

Dessa forma, esta pesquisa contribui para a literatura de Ciência de Dados Aplicada ao demonstrar como técnicas computacionais não supervisionadas podem servir como instrumentos de inteligência institucional, revelando dinâmicas organizacionais, gargalos normativos e padrões de alocação de recursos no Estado do Acre.

2 PROBLEMA DA PESQUISA

3 OBJETIVOS DA PESQUISA

Nesta seção estão estabelecidos os objetivos desta pesquisa, tanto de forma geral quanto de forma específica.

3.1 OBJETIVO GERAL

3.2 OBJETIVOS ESPECÍFICOS

- 1.
- 2.
- 3.
- 4.
- 5.

4 JUSTIFICATIVA DA PESQUISA

5 FUNDAMENTAÇÃO TEÓRICA

Nesta seção serão abordados alguns conceitos fundamentais para a realização deste trabalho, tais como:

5.1 Assunto 1

5.2 Assunto 2

5.3 Assunto 3

5.4 Trabalhos Relacionados

6 PROCEDIMENTOS METODOLÓGICOS

7 RESULTADOS

7.1 PIPELINE KDD E COBERTURA POPULACIONAL

- Processamento automatizado de 100% da base de dados do Portal da Transparência do Acre via scripts em Python.
- Análise abrangente contemplando mais de 429 mil registros de despesas públicas no período entre 2020 e 2025.

7.2 FILTRO ESTATÍSTICO DE BENFORD E Z-SCORE

7.2.1 Diagnóstico de Falsos Positivos

- Detecção de anomalias estatísticas expressivas localizadas nos Dígitos 4 ($Z = +9,97$) e 7 ($Z = +25,66$).
- A análise qualitativa de texto (NLP) revelou que esses picos não representavam fraudes mascaradas.
- Constatou-se a presença de "falsos positivos" causados diretamente por padronizações normativas, especificamente os valores tabelados de diárias civis e militares oriundos do Fundo Penitenciário.

7.3 REDES DE GRAFOS E OLIGOPÓLIOS ESTRUTURAIS

- Mapeamento de matrizes de co-ocorrência utilizando as bibliotecas *NetworkX* e *PyVis*.
- Evidenciou-se uma altíssima centralização de mercado na administração estadual.
- Identificação de um núcleo reduzido de empresas atuando simultaneamente em até 28 secretarias de estado, viabilizado pelo uso intensivo de Atas de Registro de Preço (prática de "Caronas").

7.4 ALGORITMO DE SMURFING E O ESTUDO DE CASO 4HEALTH

- O algoritmo de varredura projetado para detectar dispensa de licitação identificou um total de R\$ 12,07 milhões distribuídos em 9 repasses.

- Destinatária dos recursos: 4Health Serviços Médicos Ltda, através do Fundo Estadual de Saúde (FUNDES/SESACRE).
- A inspeção dos históricos contábeis, baseada nos processos SEI e nos Contratos 677/2023 e 862/2024, revelou a prestação continuada de serviços de anestesiologia via dispensa de licitação ao longo de 3 anos consecutivos (2023 a 2025).

7.5 DIAGNÓSTICO FORENSE

- O modelo analítico demonstrou capacidade robusta de extrapolar a detecção do fracionamento comum de pequeno valor (*smurfing*).
- Exposição de um cenário caracterizado por "emergência fabricada" ou inércia administrativa.
- O contexto anômalo detectado é respaldado pela escassez crônica de médicos anesthesiologistas na região e pelos sucessivos decretos de emergência climática emitidos no Acre.

8 CRONOGRAMA

O processo de escrita desta monografia seguirá o cronograma explicitado no Quadro 1.

Mês	Data	Dias	Atividade
Novembro	03-11-2025 até 17-11-2025	15	Escrita do Capítulo 1 - Introdução .
Novembro	18-11-2025 até 30-11-2025	13	Início da escrita do Capítulo 2 - Fundamentação Teórica .
Dezembro	01-12-2025 até 15-12-2025	15	Conclusão da escrita do Capítulo 2 - Fundamentação Teórica .
Dezembro	16-12-2025 até 23-12-2025	8	Etapa 1 e 2 (Planejamento e Identificação): Início da busca/seleção de estudos e redação do Capítulo 3 - Metodologia .
Janeiro	03-01-2026 até 12-01-2026	10	Conclusão da Etapa 1 e 2 e da redação do Capítulo 3 .
Janeiro	13-01-2026 até 31-01-2026	19	Etapa 3 e 4 (Extração e Visualização): Análise dos dados e início da redação do Capítulo 4 - Resultados .
Fevereiro	01-02-2026 até 06-02-2026	6	Conclusão da redação do Capítulo 4 - Resultados .
Fevereiro	07-02-2026 até 15-02-2026	9	Etapa 5 (Relatório): Redação do Capítulo 5 - Considerações Finais e entrega da versão completa para a orientadora.
Fevereiro	16-02-2026 até 28-02-2026	13	Período de revisão e aplicação dos ajustes finais.
Março	A definir em 03/2026	-	Preparação da apresentação e Defesa do Trabalho de Conclusão de Curso .

Fonte: Elaboração própria.

Quadro 1: Cronograma de execução da pesquisa.

REFERÊNCIAS

- BREUNIG, M. M. *et al.* Lof: Identifying density-based local outliers. **ACM SIGMOD Record**, v. 29, n. 2, p. 93–104, 2000.
- CAVALCANTI, G. H. d. V. **Aplicação da Lei de Newcomb-Benford na Identificação de Irregularidades: o exemplo dos gastos com cartões de pagamento do governo federal – CPGF**. Tese (Doutorado) — Controladoria-Geral da União (CGU), Brasília, 2014.
- GOLDSCHMIDT, R. **Data Mining e Gestão Pública**. São Paulo: Editora XYZ, 2005.
- LIU, F. T.; TING, K. M.; ZHOU, Z.-H. Isolation forest. In: **Proceedings of the 8th IEEE International Conference on Data Mining**. Pisa: IEEE, 2008.
- NIGRINI, M. J. **Benford’s Law: Applications for Forensic Accounting, Auditing, and Fraud Detection**. New Jersey: Wiley, 2012.
- NUNES, B. O. *et al.* Anomaly detection in brazilian federal government purchase cards through unsupervised learning techniques. **IEEE Access**, v. 9, p. 1–15, 2021.
- PEREIRA, J. P. T. **Ciência de Dados Aplicada na Detecção de Fraude em Demonstrações Financeiras**. Goiânia: [s.n.], 2025. Trabalho de Conclusão de Curso – PUC Goiás.